PENINGKATAN AKURASI KLASIFIKASI MIKROGRAF STOMATA MENGGUNAKAN YOLOV11 DENGAN GAMMA CORRECTION DAN CLAHE

IMPROVING ACCURACY OF STOMATA MICROGRAPH CLASSIFICATION USING YOLOV11 WITH GAMMA CORRECTION AND CLAHE

YUSRI SIMANG

D082232001

PROGRAM STUDI MAGISTER TEKNIK INFORMATIKA

FAKULTAS TEKNIK

UNIVERSITAS HASANUDDIN

GOWA

2025

PENINGKATAN AKURASI KLASIFIKASI MIKROGRAF STOMATA MENGGUNAKAN YOLOV11 DENGAN GAMMA CORRECTION DAN CLAHE

IMPROVING ACCURACY OF STOMATA MICROGRAPH CLASSIFICATION USING YOLOV11 WITH GAMMA CORRECTION AND CLAHE

Disusun Oleh

YUSRI SIMANG

D082232001

PROGRAM STUDI MAGISTER TEKNIK INFORMATIKA

FAKULTAS TEKNIK

UNIVERSITAS HASANUDDIN

GOWA

2025

PENINGKATAN AKURASI KLASIFIKASI MIKROGRAF STOMATA MENGGUNAKAN YOLOV11 DENGAN GAMMA CORRECTION DAN CLAHE

Tesis

Sebagai salah satu syarat untuk mencapai gelar magister

Program Studi Teknik Informatika

Disusun dan diajukan oleh

YUSRI SIMANG
D082232001

Kepada

PROGRAM STUDI MAGISTER TEKNIK INFORMATIKA

FAKULTAS TEKNIK

UNIVERSITAS HASANUDDIN

GOWA

2025

TESIS

PENINGKATAN AKURASI KLASIFIKASI MIKROGRAF STOMATA MENGGUNAKAN YOLOV11 DENGAN GAMMA CORRECTION DAN CLAHE

YUSRI SIMANG

D082232001

Telah dipertahankan di hadapan Panitia Ujian Magister pada 3 Desember 2025
dan dinyatakan telah memenuhi syarat kelulusan

pada

Program Studi Magister Teknik Informatika

Fakultas Teknik
Universitas Hasanuddin

Makassar

Mengesahkan:

Pembimbing Utama

Prof. Dr. Ir. Indrabayu, ST., MT., M.Bus.Sys., IPM., ASEAN. Eng.
NIP 197507162002121004

Dekan Fakultas Teknik

Universitas Hasanuddin

Prof.Dr.Eng. Ir. Muhammad Isran Ramli, ST., MT.IPM., ASEAN.Eng
NIP 19730926 200012 1 002

Ketua Program Studi

Magister Teknik Informatika

Prof. Dr. Ir. Zahir Zainuddin, M.Sc.
NIP 196404271989101002

PERNYATAAN KEASLIAN DAN PELIMPAHAN HAK CIPTA

Yang bertanda tangan di bawah ini:

Nama : Yusri Simang

NIM : D082232001

Program Studi : S2 Teknik Informatika

Dengan ini saya menyatakan bahwa, tesis yang berjudul "PENINGKATAN AKURASI KLASIFIKASI MIKROGRAF STOMATA MENGGUNAKAN YOLOV11 DENGAN GAMMA CORRECTION DAN CLAHE" adalah benar karya saya dengan arahan dari pembimbing Prof. Dr. Ir. Indrabayu, ST., MT., M.Bus.Sys., IPM, ASEAN. Eng. Karya ini belum diajukan dan sedang tidak diajukan dalam bentuk apapun kepada perguruan tinggi manapun. Sumber informasi yang berasal atau dikutip dari karya yang diterbitkan maupun tidak diterbitkan dari penulis telah disebutkan dalam teks dan dicantumkan dalam Daftar Pustaka tesis ini. Sebagian isi dari tesis ini telah diterima di konferensi internasional 1st International Conference on Research and Innovations in Information and Engineering Technology (RITECH 2025). Sebagai artikel dengan judul "Improved Accuracy of Stomata Micrograph Classification Using YOLOv11 with Gamma Correction and CLAHE". Apabila di kemudian hari terbukti atau dapat dibuktikan bahwa sebagian atau keseluruhan tesis ini adalah karya orang lain, maka saya bersedia menerima sanksi atas perbuatan tersebut berdasarkan aturan yang berlaku.

Dengan ini saya melimpahkan hak cipta karya ini dari karya tulus berupa tesis ini kepada Universitas Hasanuddin

Gowa, 22 Desember 2025

Yusri Simang
NIM. D082232001

UCAPAN TERIMA KASIH

Segala puji dan syukur penulis panjatkan ke hadirat Allah SWT atas limpahan rahmat dan karunia-Nya, sehingga tesis yang berjudul “Peningkatan Akurasi Klasifikasi Mikrograf Stomata Menggunakan YOLOv11 dengan Gamma Correction dan CLAHE” ini dapat diselesaikan sebagai salah satu syarat untuk meraih gelar Magister pada Departemen Teknik Informatika, Fakultas Teknik, Universitas Hasanuddin.

Penulis menyadari bahwa penyusunan dan penulisan tesis ini tidak terlepas dari dukungan, bimbingan, serta bantuan dari berbagai pihak. Perjalanan akademik ini penuh dengan tantangan, namun berkat doa, motivasi, dan dorongan dari orangorang terdekat, akhirnya tesis ini dapat terselesaikan dengan baik.

Dengan penuh rasa hormat dan terima kasih, penulis ingin menyampaikan apresiasi yang mendalam kepada kedua orang tua tercinta, Bapak H. Simang dan Ibu Hj. Yuliana, yang senantiasa memberikan dukungan moral, materi, serta doa yang tak henti-hentinya bagi penulis selama menempuh pendidikan. Tak lupa, penulis juga mengucapkan terima kasih kepada serta seluruh saudara dan keluarga besar yang selalu memberikan semangat, dukungan, dan motivasi di setiap langkah perjalanan akademik ini.

Penulis juga ingin mengungkapkan rasa terima kasih yang sebesar-besarnya kepada Prof. Dr. Ir. Indrabayu, ST., MT., M.Bus.Sys., IPM, ASEAN. Eng., selaku pembimbing utama, atas segala arahan, motivasi, dan bimbingan selama masa studi pascasarjana di Universitas Hasanuddin. Tak lupa, penulis mengucapkan terima kasih kepada Novy Nur R.A Mokobombang, ST.,Ms.TM.,Ph.D, dan Dr. Muhammad Abdillah Rahmat, S.T., M.T., selaku tim penguji yang telah memberikan kritik, saran, serta masukan berharga guna meningkatkan kualitas penelitian ini.

Ucapan terima kasih juga penulis sampaikan kepada Bapak Dr. Ir. Zahir Zainuddin, M.Sc., selaku Ketua Program Studi Magister Teknik Informatika atas segala bimbingan dan dukungannya selama masa perkuliahan. Penulis juga berterima kasih kepada seluruh dosen dan staf Departemen Teknik Informatika, Fakultas Teknik, Universitas Hasanuddin, yang telah memberikan ilmu, wawasan, serta berbagai bantuan dalam mendukung kelancaran studi ini.

Penghargaan yang sebesar-besarnya juga penulis sampaikan kepada rekan-rekan AIMP Research Group dan CBS Research Group, yang telah memberikan banyak bantuan dalam proses penelitian, pengambilan data, serta diskusi akademik yang sangat berarti. Begitu pula kepada teman-teman Mahasiswa S2 Angkatan IX, yang selalu memberikan dukungan, semangat, serta kebersamaan selama perjalanan studi ini.

Penulis sepenuhnya menyadari bahwa tesis ini masih memiliki keterbatasan dan kekurangan. Oleh karena itu, kritik dan saran yang membangun sangat penulis harapkan demi perbaikan dan pengembangan lebih lanjut di masa mendatang. Semoga penelitian ini dapat memberikan manfaat bagi perkembangan ilmu pengetahuan dan teknologi, khususnya dalam bidang biotani khususnya stomata..

ABSTRAK

YUSRI SIMANG**, Peningkatan Akurasi Klasifikasi Mikrograf Stomata Menggunakan Yolov11 dengan *Gamma Correction* dan *CLAHE*** (Dibimbing oleh Indrabayu)

Latar Belakang. Stomata merupakan pori mikroskopis pada permukaan daun yang berperan penting dalam pertukaran gas dan pengaturan transpirasi tanaman. Analisis morfologi stomata secara manual sering kali tidak efisien dan subjektif, sehingga diperlukan sistem otomatis berbasis kecerdasan buatan. **Tujuan.** Penelitian ini bertujuan untuk meningkatkan akurasi klasifikasi mikrograf stomata menggunakan algoritma *YOLOv11* yang dikombinasikan dengan teknik praproses *Gamma Correction* dan *CLAHE* (*Contrast Limited Adaptive Histogram Equalizatio*n). **Metode.** *Gamma Correction* digunakan untuk menormalkan pencahayaan global citra, sedangkan *CLAHE* meningkatkan kontras lokal tanpa menambah noise berlebih. Dataset terdiri dari 52.236 citra stomata empat tipe morfologi (*Anomocytic*, *Diacytic*, *Paracytic*, dan *Graminoid*) yang diperoleh dari mikroskop digital. Proses pelatihan dilakukan dengan parameter konstan untuk membandingkan model baseline dan model hasil praproses. **Hasil.** Pengujian menunjukkan bahwa penerapan kombinasi *Gamma Correction* dan *CLAHE* mampu meningkatkan *accuracy* sebesar 0,93, *precision* 0,88, *recall* 0,90, dan *mAP50* mencapai 0,95, yang lebih tinggi dibandingkan model tanpa praproses. Visualisasi hasil deteksi juga menunjukkan peningkatan kejelasan struktur stomata dan pengurangan kesalahan klasifikasi antar tipe. **Kesimpulan.** Dengan demikian, integrasi YOLOv11 dengan *Gamma Correction* dan *CLAHE* terbukti efektif dalam meningkatkan kualitas citra mikroskopis serta performa deteksi dan klasifikasi stomata secara otomatis, yang berpotensi diterapkan pada sistem analisis fisiologi tanaman berbasis kecerdasan buatan.

Kata Kunci**:** Stomata, YOLOv11, Gamma Correction, CLAHE, Pengolahan Citra, Deep Learning.

ABSTRACT

YUSRI SIMANG, **Improving Accuracy of Stomata Micrograph Classification Using Yolov11 with Gamma Correction and CLAHE** (Supervised by Indrabayu)

Background. Stomata are microscopic pores on the leaf surface that play a vital role in gas exchange and transpiration regulation in plants. Manual analysis of stomatal morphology is often inefficient and subjective, thus requiring an automated system based on artificial intelligence. **Aim.** This study aims to improve the classification accuracy of stomatal micrographs using the YOLOv11 algorithm combined with Gamma Correction and CLAHE (Contrast Limited Adaptive Histogram Equalization) preprocessing techniques. **Method.** Gamma Correction was applied to normalize global image illumination, while CLAHE enhanced local contrast without amplifying noise. The dataset consisted of 52,236 stomatal micrographs representing four morphological types (Anomocytic, Diacytic, Paracytic, and Graminoid) captured using a digital microscope. **Result.** Model training was conducted with constant parameters to compare baseline and preprocessed models. The results show that the combination of Gamma Correction and CLAHE increased the accuracy to 0.93, precision to 0.88, recall to 0.90, and mAP50 to 0.95, outperforming the baseline model. Visual detection results also demonstrate improved clarity of stomatal structures and reduced misclassification among classes. **Conclusion.** Therefore, integrating YOLOv11 with Gamma Correction and CLAHE effectively enhances microscopic image quality as well as detection and classification performance, providing a reliable approach for automated stomatal analysis in plant physiology research using artificial intelligence.

Keywords: Stomata, YOLOv11, Gamma Correction, CLAHE, Image Processing, Deep Learning.

DAFTAR ISI

Nomor Urut Halaman

LEMBAR PENGESAHAN UJIAN TESIS iii

PERNYATAAN KEASLIAN DAN PELIMPAHAN HAK CIPTA iv

UCAPAN TERIMA KASIH vi

ABSTRAK vii

ABSTRACT viii

DAFTAR ISI ix

DAFTAR TABEL x

DAFTAR GAMBAR xi

DAFTAR LAMPIRAN xiii

BAB I PENDAHULUAN 1

1.1 Latar Belakang 1

1.2 Landasan Teori 3

1.2.1 Stomata 3

1.2.2 Mikroskop dan Mikrograf 4

1.2.3 Pengolahan Citra 5

1.2.4 Visi Komputer 5

1.2.5 Deteksi Objek 5

1.2.6 *YOLOv11* (*You Only Look Once*) 6

1.2.7 *Gamma Correction* 8

1.2.8 *CLAHE* (*Contrast Limited Adaptive Histogram Equalization*) 9

1.3 Perumusan Masalah 10

1.4 Tujuan dan Manfaat 10

1.4.1 Tujuan 10

1.4.2 Manfaat 10

BAB II METODE PENELITIAN 11

2.1 Jenis Penelitian 11

2.2 Tahapan Penelitian 11

2.3 Sumber Data 12

2.4 Perangkat Penelitian 13

2.5 Rancangan Sistem 13

2.5.1 Pengumpulan Data 14

2.5.2 *Preprocessing* 14

2.5.3 Gamma Correction 15

2.5.4 CLAHE (*Contrast Limited Adaptive Histogram Equalization)* 16

2.5.5 *Split Data* 19

2.5.6 Augmentasi Data Latih 19

2.5.7 *Input* Data Training 20

2.5.8 *Training* Model *YOLOv11* 20

2.5.9 *Input* Data Validasi 28

2.5.10 Validasi Model *YOLOv11* 29

2.5.11 Evaluasi Model 29

2.5.12 *Hyperparameter Tuning* 29

2.5.13 Model *Classification* 29

2.5.14 *Input* Data Testing 30

2.5.15 Klasifikasi dan Deteksi Stomata 30

2.5.16 Evaluasi Hasil Klasifikasi 30

BAB III HASIL DAN PEMBAHASAN 33

3.1 Hasil 33

3.1.1 Hasil Praproses Citra 33

3.1.2 Hasil Training Model 36

3.1.3 Hasil Testing 39

3.1.4 Visualisasi Hasil Deteksi 43

3.2 Pembahasan 45

BAB IV PENUTUP 48

4.1 Kesimpulan 48

4.2 Saran 48

DAFTAR PUSTAKA 49

LAMPIRAN 51

DAFTAR TABEL

Nomor Urut Halaman

Tabel 1. Perbandingan *YOLOv8-Yolov11* 7

Tabel 2. Nilai Histogram 17

Tabel 3. Nilai *CDF* 17

Tabel 4. Nilai Hasil Perhitungan *CLAHE* 18

Tabel 5. *Split* Dataset 19

Tabel 6. Distribusi Label Dataset 19

Tabel 7. Distribusi *Augmentasi* Data *Training* 20

Tabel 8. Hasil *Training* Model 38

DAFTAR GAMBAR

Nomor Urut Halaman

Gambar 1. Tipe Stomata 3

Gambar 2. Mikrograf Stomata 4

Gambar 3. Arsitektur *YOLO* 6

Gambar 4. Penerapan *Gamma Correction* 9

Gambar 5. Penerapan *CLAHE* 10

Gambar 6. Tahapan Penelitian 11

Gambar 7. Rancangan Sistem 13

Gambar 8. Proses Pengambilan Data 14

Gambar 9. Proses Anotasi Labelling 14

Gambar 10. Penerapan *Augmentasi* 19

Gambar 11. Inputan YOLOv11 20

Gambar 12. Proses Konvolusi 21

Gambar 13. Proses Blok C3k2F 22

Gambar 14. Proses Blok C3k2T 23

Gambar 15. Proses Blok SPPF 24

Gambar 16. Proses Blok C2PSA 25

Gambar 17. Dekode *Bounding Box* 27

Gambar 18. Probabilitas Kelas 28

Gambar 19. *Confusion Matrix* 31

Gambar 20. Hasil Praproses Citra 34

Gambar 21. Hasil *Peak Signal-to-Noise Ratio (PSNR)* 35

Gambar 22. *Confusion Matrix YOLOv11 Baseline* dengan *YOLOv11+Gamma+CLAHE* 37

Gambar 23. Hasil Testing Pembesaran 3 39

Gambar 24. Hasil Testing Pembesaran 4 41

Gambar 25. *Confusion Matrix* Pembesaran 3 42

Gambar 26. *Confusion Matrix* Pembesaran 4 43

Gambar 27. Visualisasi Hasil Deteksi 44

DAFTAR LAMPIRAN

Nomor Urut Halaman

Lampiran 1. *Code Gamma Correction and CLAHE* 52

Lampiran 2. *Code Training Model* 52

Lampiran 3. *Code Testing Model* 53

Lampiran 4. *Result Training Model* 54

BAB I
PENDAHULUAN

1.1 Latar Belakang

Stomata merupakan pori-pori mikroskopis pada permukaan daun dan batang tanaman yang berperan penting dalam pertukaran gas, yaitu penyerapan karbon dioksida (CO_2) untuk fotosintesis serta pelepasan oksigen (O_2) dan uap air melalui transpirasi. Fungsi stomata sangat krusial dalam menjaga keseimbangan air dan suhu tanaman, serta menjadi indikator penting dalam studi adaptasi tanaman terhadap lingkungan. Karakteristik seperti ukuran dan kerapatan stomata mencerminkan efisiensi metabolisme tumbuhan dan digunakan dalam analisis fisiologis, terutama pada kondisi cekaman lingkungan seperti kekeringan dan peningkatan CO_2 atmosferik (Haworth et al., 2023).

Stomata memiliki peran yang sangat penting dalam mengatur keseimbangan antara proses fotosintesis dan transpirasi tanaman. Melalui mekanisme buka-tutup sel penjaga (*guard cells*), stomata mengontrol difusi gas seperti karbon dioksida (CO_2) untuk fotosintesis dan pelepasan uap air ke atmosfer. Efisiensi fungsi stomata berpengaruh langsung terhadap produktivitas dan adaptasi tanaman terhadap stres lingkungan. Menurut Feng et al., (2021), variasi ukuran dan kerapatan stomata merupakan respons fisiologis yang adaptif terhadap perubahan intensitas cahaya dan ketersediaan air. Penelitian oleh Mohanasundaram et al., (2022) juga menunjukkan bahwa spesies tanaman dengan kerapatan stomata tinggi memiliki kemampuan fotosintesis lebih efisien dalam kondisi CO_2 rendah, tetapi lebih rentan terhadap kehilangan air. Sementara itu, Huang et al. (2023) menegaskan bahwa pengaturan morfologi dan distribusi stomata menjadi indikator utama dalam menilai ketahanan tanaman terhadap kekeringan serta perubahan iklim global. Dengan demikian, analisis karakteristik stomata, seperti ukuran, bentuk, dan kerapatan, tidak hanya penting untuk memahami fungsi fisiologis tanaman, tetapi juga menjadi dasar bagi pemuliaan tanaman yang lebih adaptif terhadap lingkungan yang berubah.

Pengamatan stomata secara manual masih sering digunakan dalam banyak penelitian. Namun, proses manual ini memiliki keterbatasan dalam hal efisiensi waktu, subjektivitas penilai, serta potensi kesalahan dalam mengidentifikasi struktur stomata terutama dalam jumlah besar atau citra berkualitas rendah (Nature Research Intelligence., 2023). Seiring dengan berkembangnya teknologi citra digital dan kecerdasan buatan, muncul peluang untuk mengotomatisasi proses ini secara lebih akurat, efisien, dan konsisten.

Urgensi penelitian dalam otomatisasi deteksi stomata berbasis kecerdasan buatan semakin meningkat dalam beberapa tahun terakhir. Hal ini didorong oleh kebutuhan untuk memperoleh data morfologi stomata secara cepat, akurat, dan dalam jumlah besar guna mendukung analisis fisiologis tanaman. Sultana et al., (2021) menunjukkan bahwa penerapan *deep learning* pada pengenalan stomata daun kedelai mampu meningkatkan efisiensi pengolahan data hingga lima kali lipat dibandingkan metode konvensionalLebih lanjut, Murphy et al., (2025) menegaskan bahwa penerapan

kecerdasan buatan dalam *image-based plant phenotyping* menjadi kunci dalam memahami respon adaptif tanaman terhadap stres lingkungan. Oleh karena itu, penelitian mengenai otomatisasi deteksi stomata berbasis AI menjadi semakin mendesak untuk dikembangkan, terutama sebagai langkah menuju sistem analisis morfologi tanaman yang efisien, objektif, dan dapat diandalkan dalam berbagai kondisi lingkungan.

Salah satu pendekatan yang menjanjikan adalah dengan menggunakan metode deteksi objek berbasis *deep learning*. *YOLO* (*You Only Look Once*) merupakan algoritma deteksi objek satu tahap yang terkenal karena kecepatannya dan akurasi tinggi dalam memproses gambar secara *real-time*. Penelitian sebelumnya menunjukkan bahwa *YOLOv5* berhasil mendeteksi stomata dengan cukup baik pada citra mikrograf tanaman seperti jagung, beras, dan kapas (Qiu et al., 2022). Seiring dengan evolusinya, *YOLO* kini telah mencapai versi ke-11 (*YOLOv11*), dengan berbagai peningkatan arsitektur seperti modul *C2f*, *attention mechanism*, dan *Spatial Pyramid Pooling Fast* (SPPF) yang secara signifikan meningkatkan kemampuan deteksi objek kecil seperti stomata.

Namun, penggunaan algoritma deteksi objek tidak terlepas dari kualitas citra yang diolah. Citra mikroskopis sering kali mengalami berbagai kendala visual seperti pencahayaan yang tidak merata, *noise*, dan kontras rendah yang menyulitkan proses deteksi. Oleh karena itu, diperlukan proses prapengolahan (*preprocessing*) citra guna meningkatkan kualitas visual sebelum dilakukan klasifikasi. Dua metode praproses yang umum digunakan adalah *Gamma Correction* dan *CLAHE* (*Contrast Limited Adaptive Histogram Equalization*). *Gamma Correction* bertujuan untuk menyesuaikan kecerahan citra melalui manipulasi distribusi intensitas piksel, sedangkan *CLAHE* meningkatkan kontras lokal tanpa memperkuat *noise* secara berlebihan.

CLAHE dan *Gamma Correction* telah terbukti meningkatkan performa berbagai model deteksi, khususnya dalam domain medis. Misalnya, Benchabane & Charif (2025) menggabungkan *CLAHE* dan Gamma *Correction* dalam analisis *X-ray COVID-19* menggunakan arsitektur DenseNet201,. Penerapan Dalam konteks botani, *CLAHE* juga telah digunakan untuk menajamkan tepi sel epidermis dan membuka struktur stomata dengan lebih jelas, sehingga membantu dalam proses deteksi otomatis. Kombinasi keduanya memiliki potensi besar, namun penerapannya pada klasifikasi stomata menggunakan arsitektur *YOLOv11* masih belum banyak dijelajahi dalam literatur terkini.

Lebih lanjut, penelitian terkini oleh Zhang et al., (2023) memperkenalkan metode *rotating stomata detection* dengan model *DeepRSD*, yang mampu mendeteksi orientasi acak stomata dan mengukur *stomatal conductance* secara otomatis. Metode ini tidak hanya mendeteksi bentuk, tetapi juga menyertakan fungsi kerugian khusus untuk *conductance*, menghasilkan akurasi hingga 94,3 % pada daun jagung menandakan bahwa klasifikasi stomata memiliki peran penting dalam evaluasi fisiologis tanaman yang lebih kompleks

Dengan demikian, penelitian ini bertujuan untuk menggabungkan kekuatan dari arsitektur deteksi terkini (*YOLOv11*) dan dua teknik peningkatan kualitas citra (*Gamma Correction* dan *CLAHE*) untuk membangun sistem klasifikasi stomata yang unggul.

Melalui evaluasi performa dengan metrik seperti *accuracy*, *precision*, *recall*, dan *mAP*, penelitian ini diharapkan dapat memberikan kontribusi signifikan dalam pengembangan sistem analisis citra mikroskopis berbasis AI untuk bidang fisiologi tanaman dan pertanian presisi.

1.2 Landasan Teori

1.2.1 Stomata

Stomata adalah pori-pori mikroskopis yang umumnya terdapat pada permukaan epidermis daun dan batang muda tanaman. Struktur ini dibentuk oleh dua sel penjaga (*guard cells*) yang mengapit celah sempit yang disebut pori stomata. Fungsi utama stomata adalah sebagai jalur pertukaran gas antara jaringan internal tumbuhan dan atmosfer, termasuk dalam proses fotosintesis dan respirasi (Zhang et al., 2022).

Stomata memiliki peran penting dalam pengambilan karbon dioksida (CO_2) dari atmosfer untuk fotosintesis serta dalam pelepasan oksigen (O_2) dan uap air hasil transpirasi. Oleh karena itu, stomata menjadi salah satu komponen kunci dalam regulasi gas dan keseimbangan air pada tumbuhan. Dalam konteks fisiologi tanaman, parameter stomata seperti jumlah, ukuran, dan kerapatan sering digunakan sebagai indikator dalam menilai efisiensi metabolisme, adaptasi terhadap lingkungan, serta ketahanan terhadap stres abiotik (Nature Research Intelligence., 2023).

Stomata dapat diklasifikasikan berdasarkan susunan dan jenis sel tetangga yang mengelilingi sel penjaga. Beberapa tipe morfologi stomata yang umum ditemukan dalam berbagai spesies tanaman antara lain:

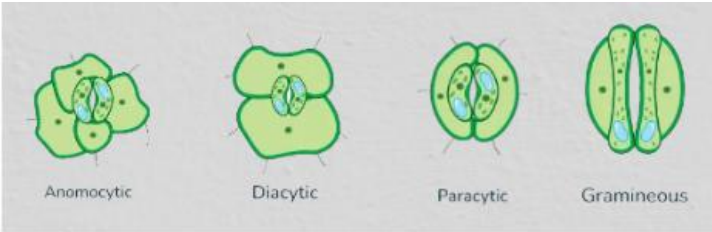

Gambar 1. Tipe Stomata

Source: https://www.geeksforgeeks.org/biology/types-of-stomata/

1. **Anomositik (*Anomocytic* (A))**: Stomata ini dikelilingi oleh sel-sel epidermis biasa yang tidak memiliki ciri khusus, ukuran dan bentuknya tidak berbeda nyata dari sel lainnya.

2. **Diastik (*Diacytic* (D))**: Stomata ini dikelilingi oleh dua sel tetangga yang posisinya saling tegak lurus terhadap celah stomata.

3. **Parasitik (*Paracytic* (P))**: Memiliki satu atau dua sel tetangga yang letaknya sejajar dengan arah celah stomata.

4. **Graminoid *(Graminaceous* (G))**: Stomata memiliki sel penjaga berbentuk dumbbell (seperti barbel), khas pada tanaman rumput.

Jenis dan distribusi morfologi stomata ini bervariasi antar spesies tanaman dan sering digunakan dalam kajian taksonomi, ekologi, serta identifikasi adaptasi terhadap lingkungan. Dalam praktik ilmiah, pengamatan stomata juga penting untuk mendukung studi-studi lanjutan dalam bidang fisiologi tanaman, agronomi, dan bioteknologi tanaman.

Karena karakteristik stomata dapat dijadikan parameter fisiologis yang penting, maka proses identifikasi dan klasifikasi stomata dari data citra menjadi fokus penting dalam banyak penelitian. Upaya untuk mempercepat dan mempermudah proses ini kini banyak dikembangkan melalui teknologi pengolahan citra digital dan kecerdasan buatan.

1.2.2 Mikroskop dan Mikrograf

Mikroskop adalah alat optik yang digunakan untuk memperbesar objek kecil agar dapat diamati secara visual. Mikroskop cahaya merupakan jenis yang paling umum digunakan dalam studi biologis, termasuk pengamatan stomata, karena dapat menampilkan struktur jaringan seperti sel epidermis secara jelas tanpa memerlukan teknik preparasi yang kompleks. Selain itu, mikroskop cahaya dapat digunakan bersama kamera digital untuk menghasilkan citra mikroskopis atau mikrograf (Gibbs et al., 2021).

Mikrograf adalah citra hasil tangkapan mikroskop yang digunakan sebagai data visual dalam analisis. Dalam penelitian ini, mikrograf stomata menjadi *input* utama bagi sistem klasifikasi otomatis berbasis *deep learning*. Namun, kualitas mikrograf sangat memengaruhi hasil deteksi. Masalah seperti kontras rendah atau pencahayaan tidak merata sering muncul, sehingga diperlukan prapengolahan citra untuk meningkatkan kualitas visual, adapaun contoh mikrograf stomata pada gambar 2.

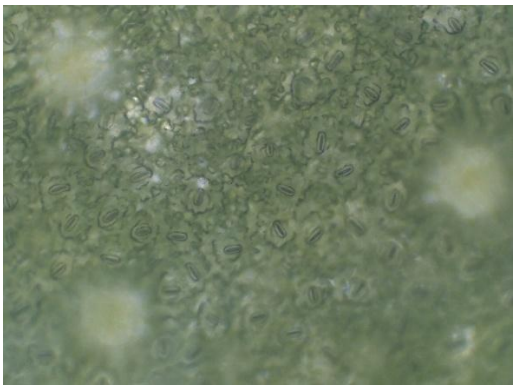

Gambar 2. Mikrograf Stomata

Teknik prapengolahan yang umum digunakan adalah *CLAHE* untuk meningkatkan kontras lokal, dan *Gamma Correction* untuk menyesuaikan pencahayaan. Kombinasi kedua teknik ini terbukti efektif meningkatkan kejelasan objek mikroskopis dan mendukung akurasi klasifikasi (Chang et al., 2018). Penelitian oleh Gibbs et al., (2021)

menunjukkan bahwa mikrograf berkualitas tinggi yang telah diproses mampu meningkatkan akurasi deteksi stomata secara signifikan.

1.2.3 Pengolahan Citra

Pengolahan citra digital (*digital image processing*) adalah serangkaian proses matematis dan algoritmik yang diterapkan pada citra digital untuk meningkatkan kualitas visual, mengekstrak informasi, atau mempersiapkan citra untuk analisis lanjutan oleh sistem komputer. Dalam konteks penelitian ini, pengolahan citra digital digunakan untuk memperjelas struktur stomata pada citra mikroskopik sebelum dilakukan klasifikasi menggunakan metode *deep learning* (Gonzalez & Woods, 2022).

Pengolahan citra sangat penting dalam sistem berbasis pembelajaran mesin atau deep learning karena kualitas input sangat menentukan hasil klasifikasi atau deteksi. Pada penelitian ini, tahap praproses berperan memastikan fitur visual stomata tampil jelas dan konsisten sehingga lebih mudah dikenali oleh YOLOv11. Dengan mengurangi noise, menyeimbangkan pencahayaan, dan menajamkan struktur penting, model dapat mengekstraksi fitur secara lebih akurat dan menghasilkan deteksi yang lebih stabil.

1.2.4 Visi Komputer

Visi komputer adalah cabang dari kecerdasan buatan yang memungkinkan komputer untuk menafsirkan informasi visual dari citra atau video secara otomatis. Tujuannya adalah agar sistem komputer dapat “melihat” dan memahami objek seperti manusia, dengan cara mengekstrak dan menganalisis fitur-fitur penting dari gambar digital (Szeliski, 2022).

Dalam penelitian ini, visi komputer digunakan untuk mendeteksi dan mengklasifikasikan stomata dari citra mikroskopis secara otomatis. Pendekatan ini menggantikan metode manual yang cenderung lambat dan subjektif. Dengan bantuan algoritma *deep learning* seperti *YOLOv11*, sistem dapat mengenali objek kecil seperti stomata secara cepat dan akurat. Komponen utama dalam sistem visi komputer mencakup akuisisi citra, praproses, ekstraksi fitur, dan klasifikasi. Semua tahapan ini saling terhubung dan mendukung proses analisis citra secara menyeluruh, mulai dari pengambilan gambar hingga interpretasi hasil.

1.2.5 Deteksi Objek

Deteksi objek (*object detection*) adalah cabang dari visi komputer yang berfokus pada identifikasi dan lokalisasi objek-objek tertentu dalam gambar atau video. Proses ini mencakup pengenalan jenis objek serta penentuan posisi objek tersebut dalam gambar. Deteksi objek merupakan langkah penting dalam berbagai aplikasi seperti pengawasan keamanan, kendaraan otonom, analisis video, dan realitas tertambah (*Augmented Reality*) (Zou et al., 2019).

Adapun komponen utama dalam deteksi objek dimulai dengan proses untuk menyiapkan gambar agar lebih mudah dianalisis. Teknik ini termasuk penyesuaian

kontras, pengurangan *noise*, dan transformasi gambar untuk meningkatkan kualitas gambar dan membuat fitur penting lebih menonjol. Mengidentifikasi dan mengekstrak fitur penting dari gambar, seperti tepi, sudut, tekstur, dan pola warna. Fitur ini digunakan sebagai *input* untuk algoritma deteksi objek. Menggunakan model pembelajaran mesin atau pembelajaran mendalam untuk mengenali dan mengklasifikasikan objek dalam gambar berdasarkan fitur yang diekstraksi. Menentukan lokasi objek dalam gambar, biasanya dengan menggambar kotak pembatas (*bounding box*) di sekitar objek yang terdeteksi.

1.2.6 *YOLOv11* (*You Only Look Once*)

YOLO (*You Only Look Once*) merupakan salah satu algoritma deteksi objek paling populer dalam bidang visi komputer. Pendekatan *YOLO* mengklasifikasikan dan melakukan prediksi lokasi objek dalam satu tahap secara langsung pada keseluruhan citra, sehingga menghasilkan sistem deteksi yang cepat dan efisien (Redmon et al., 2016). Sejak pertama kali dikembangkan, *YOLO* terus mengalami penyempurnaan, dan versi terbarunya yaitu *YOLOv11* menawarkan peningkatan baik dari sisi akurasi maupun efisiensi, khususnya dalam mendeteksi objek kecil.

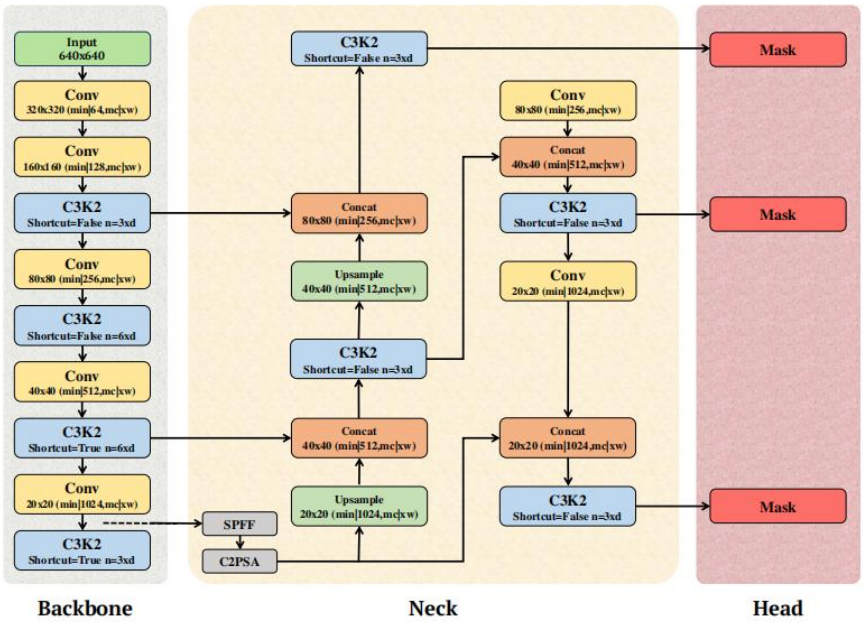

Gambar 3. Arsitektur *YOLO*

Source: https://medium.com/thedeephub/the-architecture-of-yolov11-a-leap-in-object-detection-2ce1e946c74a

Gambar 3 menampilkan arsitektur *YOLOv11,* dimana *YOLOv11* merupakan pengembangan dari arsitektur *YOLOv8* yang dilengkapi dengan beberapa inovasi, seperti modul *C2f* yang menggantikan *C3* untuk ekstraksi fitur yang lebih ringan, *SPPF++*

untuk menangkap informasi *spasial multi-skala*, serta *anchor-free detection head* yang memungkinkan fleksibilitas deteksi terhadap objek dengan ukuran dan bentuk yang bervariasi. Kombinasi modul-modul tersebut menjadikan *YOLOv11* mampu mendeteksi objek kecil seperti stomata dalam citra mikroskopis secara lebih akurat.

YOLOv11 juga meningkatkan proses *Non-Maximum Suppression* (NMS) untuk menghindari deteksi objek yang tumpang tindih, yang sebelumnya menjadi salah satu keterbatasan dalam pendeteksian multi-objek kecil dalam satu bidang citra. Model ini dilatih menggunakan teknik *augmentasi* data dan *loss function* yang telah disesuaikan untuk menyeimbangkan antara klasifikasi dan prediksi lokasi objek.

Beberapa penelitian terkini menunjukkan potensi besar *YOLOv11* dalam bidang botani dan fisiologi tanaman. Misalnya, penelitian oleh (Yang et al., 2025) mengembangkan *StomaYOLO*, model ringan berbasis *YOLOv11* untuk mendeteksi sel penjaga stomata pada daun jagung dengan *mean Average Precision* (*mAP*) mencapai 91,8%, menunjukkan efisiensi tinggi dalam mendeteksi objek mikroskopis dengan variasi bentuk yang kompleks. Selain itu, (Tang et al., 2025) melalui model *YOLOv11-AIU* berhasil menerapkan arsitektur *YOLOv11* untuk deteksi penyakit *early blight* pada tomat, yang juga menyoroti kemampuan model ini dalam mengidentifikasi pola morfologi kecil pada jaringan tanaman. Hasil-hasil tersebut menegaskan bahwa *YOLOv11* memiliki potensi tinggi untuk diterapkan pada analisis citra mikroskopis tanaman, termasuk dalam deteksi dan klasifikasi stomata.

Tabel 1. Perbandingan *YOLOv8-Yolov11*

Versi	***Precision***	***Recall***	***mAP***	***mAP@50–95***	***Val Box Loss***	***Val Cls Loss***	***Val DFL Loss***	***Computation Time (s)***
YOLOv8	0.91931	0.88889	0.94618	0.50840	1.59822	0.71588	1.28544	8376.94
YOLOv9	0.91602	0.89876	0.95256	0.51298	1.57651	0.65708	1.27104	10337.31
YOLOv10	0.85307	0.84475	0.91822	0.51182	3.10694	1.46670	2.50162	7524.26
YOLOv11	0.93348	0.88631	0.95152	0.51488	1.57081	0.71905	1.28165	4542.97

Source: Utiarahman et al., 2025.
https://doi.org/10.1109/NMITCON65824.2025.11188393

Penelitian terkini oleh Utiarahman et al., (2025) melakukan evaluasi komprehensif terhadap empat arsitektur *YOLO* generasi terbaru, yaitu *YOLOv8*, *YOLOv9*, *YOLOv10*, dan *YOLOv11*, dalam mendeteksi serta mengklasifikasikan tipe morfologi stomata pada citra mikroskopis daun tanaman herbal. Berdasarkan hasil pengujian kuantitatif, *YOLOv11* menunjukkan performa terbaik dengan nilai *precision* tertinggi sebesar 0.93348, *mAP* sebesar 0.95152, dan *mAP@50–95* sebesar 0.51488, disertai waktu komputasi tercepat yakni 4.542,97 detik. Model ini juga memiliki nilai *validation loss* yang stabil (*Val Box Loss*: 1.57081; *Val Cls Loss*: 0.71905; *Val DFL Loss*: 1.28165), menandakan efisiensi tinggi dalam proses prediksi.

Sebagai perbandingan, *YOLOv9* memperoleh recall tertinggi sebesar 0.89876 serta *validation loss* terendah, menandakan kemampuannya yang baik dalam mendeteksi seluruh objek stomata secara menyeluruh. Namun demikian, *YOLOv11* dinilai lebih unggul secara keseluruhan karena mampu mencapai keseimbangan optimal antara akurasi deteksi, efisiensi komputasi, dan kestabilan hasil. Sementara itu, *YOLOv10* menunjukkan performa paling rendah akibat nilai *loss* yang tinggi, sedangkan *YOLOv8* masih menunjukkan hasil kompetitif namun belum melampaui dua versi teratas.

Berdasarkan hasil tersebut, dapat disimpulkan bahwa *YOLOv11* menjadi model paling tepat untuk digunakan dalam penelitian ini karena mampu memberikan hasil deteksi yang akurat dengan waktu pemrosesan yang jauh lebih cepat. Keunggulan ini menjadikan *YOLOv11* sebagai model terkini berperforma unggul dalam otomasi analisis citra mikroskopis, khususnya untuk klasifikasi morfologi stomata yang menuntut presisi tinggi dan efisiensi waktu.

Dalam penelitian ini, *YOLOv11* dipilih karena kemampuannya dalam mendeteksi objek kecil, dengan efisiensi tinggi dan arsitektur yang lebih ringan dibandingkan model dua tahap seperti *Faster R-CNN*. Model ini digunakan untuk mendeteksi dan mengklasifikasikan stomata pada citra mikroskopis, khususnya setelah citra ditingkatkan kualitasnya menggunakan teknik *Gamma Correction* dan *CLAHE*.

1.2.7 *Gamma Correction*

Gamma Correction adalah teknik pemrosesan citra digital yang digunakan untuk menyesuaikan kecerahan (*brightness*) dan kontras gambar dengan mengoreksi hubungan *nonlinier* antara intensitas cahaya yang ditangkap oleh sensor dan yang ditampilkan oleh perangkat (W. Wang et al., 2021). Secara umum, gambar digital mentah yang diperoleh dari sensor cenderung terlihat terlalu gelap atau terlalu terang jika tidak dilakukan koreksi gamma. Proses *Gamma Correction* dilakukan dengan menerapkan fungsi:

$$\boldsymbol{I_{out}} = \frac{\boldsymbol{I_{in}}}{\mathbf{255}} \tag{1}$$

di mana:
I_{in} adalah intensitas asli dari piksel,
I_{out} adalah intensitas keluaran setelah koreksi,
γ adalah nilai gamma (jika γ<1, gambar menjadi lebih terang; jika γ>1, gambar menjadi lebih gelap).

Seiring dengan perkembangan teknologi pengolahan citra dan pembelajaran mendalam, penerapan *Gamma Correction* telah berevolusi dari teknik linier sederhana menjadi pendekatan adaptif berbasis jaringan saraf. Penelitian terbaru oleh (Y. Wang et al., 2023) melalui *Illumination-Aware Gamma Correction and Complete Image Modelling Network* menunjukkan bahwa koreksi gamma adaptif yang mempertimbangkan distribusi pencahayaan lokal mampu meningkatkan kualitas citra secara signifikan pada kondisi cahaya rendah. Pendekatan ini tidak hanya memperbaiki kecerahan, tetapi juga mempertahankan detail tekstur penting yang sebelumnya hilang akibat pencahayaan

tidak merata. Sementara itu, Weng et al., (2024) mengembangkan *Lightweight Low-Light Image Enhancement Network* yang menggabungkan *Gamma Correction* dengan *channel prior*, menghasilkan peningkatan visibilitas citra dengan efisiensi komputasi tinggi, sehingga cocok untuk aplikasi *real-time*. Penelitian-penelitian tersebut menunjukkan bahwa *Gamma Correction* kini bukan sekadar tahap praproses konvensional, melainkan telah menjadi bagian integral dalam pipeline pembelajaran mendalam untuk peningkatan kualitas citra. Dalam konteks penelitian ini, penerapan *Gamma Correction* pada citra mikrograf stomata diharapkan dapat meningkatkan kontras dan visibilitas struktur mikroskopis sehingga mendukung performa model deteksi berbasis YOLOv11 secara lebih optimal.

Penerapan *Gamma Correction* sangat penting dalam pengolahan citra mikroskopis, termasuk mikrograf stomata, karena membantu meningkatkan visibilitas detail struktur halus yang tidak terlihat jelas pada pencahayaan asli (Jeon et al., 2024). Dalam konteks deteksi objek menggunakan *deep learning* seperti *YOLO*, kualitas pencahayaan sangat memengaruhi akurasi deteksi. Oleh karena itu, *Gamma Correction* digunakan sebagai salah satu tahap praproses untuk memastikan kontras dan distribusi cahaya optimal pada gambar *input* sebelum dilakukan pelatihan model (Yu et al., 2021). Gambar 4 menampilkan penerapan *gamma correction.*

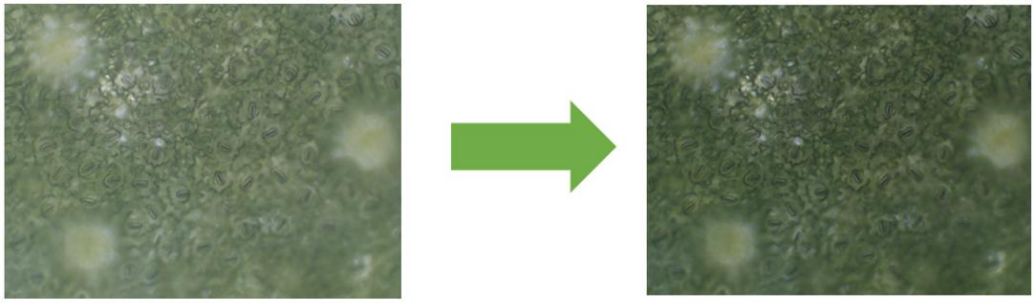

(a) Gambar Asli (b) Gambar Hasil Gamma

Gambar 4. Penerapan *Gamma Correction*

1.2.8 *CLAHE* (*Contrast Limited Adaptive Histogram Equalization*)

CLAHE adalah metode peningkatan kontras citra yang bekerja secara lokal dengan membagi gambar ke dalam beberapa bagian kecil (*tiles*), kemudian melakukan *equalization* pada masing-masing bagian. Berbeda dengan metode histogram *equalization* biasa, *CLAHE* menggunakan parameter *clip limit* untuk mencegah peningkatan kontras yang berlebihan, sehingga mampu mengurangi efek *noise*.

Metode *Contrast Limited Adaptive Histogram Equalization* (CLAHE) telah banyak digunakan dalam peningkatan kualitas citra karena kemampuannya memperbaiki kontras lokal tanpa memperkuat noise secara berlebihan. Dalam penelitian terbaru ŞENGÖZ et al., (2022) memperlihatkan bahwa penggunaan CLAHE sebagai bagian dari pipeline meningkatkan skor F1 dari 93 % menjadi 98 % dalam klasifikasi gambar histopatologi ketika dibandingkan model *CNN* tanpa preprocessing. Selanjutnya, Huang Guoand Xu, (2021)mengembangkan model enhancement citra yang

menggabungkan operator diferensial fraksional orde variabel dengan CLAHE, untuk memperkuat tepi dan tekstur citra.

Dalam beberapa penelitian terkini, penggunaan *CLAHE* terbukti meningkatkan performa deteksi pada citra medis dan mikroskopis, termasuk citra stomata, dengan cara memperjelas detail morfologi yang sulit terlihat (Liu et al., 2021).Oleh karena itu, dalam penelitian ini, *CLAHE* digunakan sebagai tahap praproses untuk meningkatkan kejelasan struktur stomata sebelum dilakukan klasifikasi oleh model *YOLOv11*. Gambar 5 menampilkan penerapan *CLAHE.*

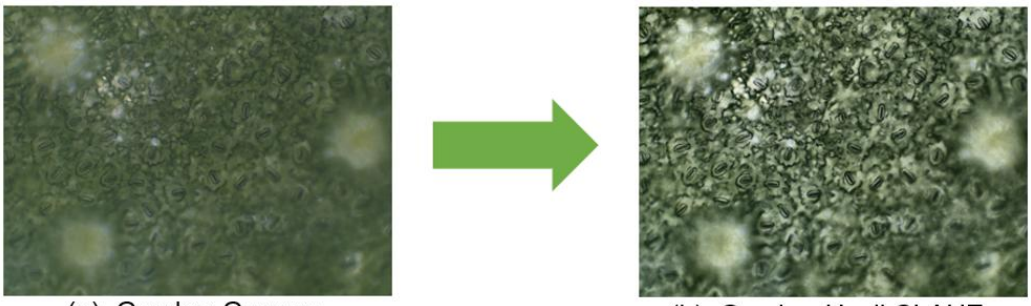

(a) Gambar Gamma (b) Gambar Hasil CLAHE

Gambar 5. Penerapan *CLAHE*

1.3 Perumusan Masalah

Berdasarkan latar belakang masalah di atas, maka rumusan masalah pada penelitian ini adalah sebagai berikut:

1. Sejauh mana model *YOLOv11* mampu mengklasifikasikan stomata dengan tingkat akurasi yang tinggi?
2. Bagaimana pengaruh penerapan *Gamma Correction* dan *CLAHE* terhadap peningkatan kinerja klasifikasi citra stomata pada model *YOLOv11*?

1.4 Tujuan dan Manfaat

1.4.1 Tujuan

Tujuan yang ingin dicapai pada penelitian ini yaitu:

1. Meningkatkan akurasi kalsifikasi stomata yang memiliki warna hampir sama dengan daun menggunakan algoritma *YOLOv11*, *Gamma Correction* dan *CLAHE*.
2. Mengevaluasi pengaruh teknik peningkatan *Gamma Correction* dan *CLAHE* terhadap performa model *YOLOv11* dalam mengklasifikasi stomata berbagai kondisi pencahayaan dan latar belakang yang kompleks.

1.4.2 Manfaat

Adapun manfaat yang dapat diperoleh dari penelitian ini yaitu:

1. Menyediakan sistem klasifikasi stomata yang otomatis, cepat, dan akurat untuk mendukung analisis tanaman.
2. Menjadi referensi dalam penerapan kombinasi *deep learning* dan peningkatan citra untuk objek mikroskopis di bidang informatika dan pertanian.

BAB II
METODE PENELITIAN

2.1 Jenis Penelitian

Jenis penelitian ini merupakan penelitian yang bersifat eksperimental dan analisis sehingga dapat dilakukan dengan metode studi pustaka (*library research*), melalui *beberapa* literatur seperti buku, jurnal, pro siding atau artikel ilmiah lainnya, metode pengumpulan data lapangan (*field research*), perancangan sistem, dan analisis menggunakan metode pengolahan citra (*Image Processing*).

2.2 Tahapan Penelitian

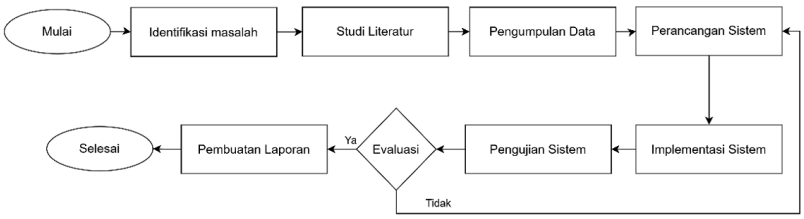

Gambar 6. Tahapan Penelitian

Pada gambar 6 diatas akan di paparkan tahapan penelitian, tahapan yang diusulkan adalah sebagai berikut:

Berikut merupakan penjelasan tentang tahapan-tahapan yang dilakukan selama proses penelitian pada Gambar:

1. Identifikasi masalah adalah tahap awal untuk mengidentifikasi permasalahan yang melatarbelakangi penelitian, yaitu rendahnya akurasi klasifikasi stomata pada citra mikroskopik akibat kualitas citra yang buruk (kontras rendah pencahayaan tidak merata). Permasalahan ini berdampak pada kinerja algoritma deteksi, khususnya dalam konteks citra mikroskopik biologis.
2. Setelah permasalahan diidentifikasi, tahap selanjutnya adalah melakukan studi literatur untuk mendalami teori dan pendekatan yang relevan dengan penelitian ini. Studi ini mencakup penelusuran terhadap teknik-teknik pengolahan citra digital seperti *Gamma Correction* dan *CLAHE*, serta studi mendalam terhadap algoritma *YOLO*, khususnya versi terbaru yaitu *YOLOv11* yang dikenal memiliki keunggulan dalam kecepatan dan akurasi deteksi. Studi literatur ini juga membantu dalam merancang kerangka metodologi penelitian dan mendukung argumen pemilihan metode yang digunakan.
3. Pada tahap ini dilakukan pengumpulan data set berupa citra mikrograf stomata dari berbagai jenis daun. Citra diambil menggunakan mikroskop digital dengan resolusi tinggi untuk memastikan detail stomata terekam dengan baik. Proses pengambilan data dilakukan secara sistematis, dengan memperhatikan pencahayaan dan posisi fokus agar diperoleh variasi data yang merepresentasikan kondisi riil di lapangan.

Data set kemudian dilabeli secara manual untuk keperluan pelatihan dan pengujian model deteksi.

4. Setelah data tersedia, dilakukan perancangan sistem secara menyeluruh, mulai dari alur praproses citra, penerapan algoritma *YOLOv11*, hingga evaluasi performa sistem. Praproses mencakup penerapan *Gamma Correction* untuk meningkatkan pencahayaan dan *CLAHE* untuk meningkatkan kontras lokal pada citra. Desain sistem juga mencakup struktur direktori data set, pemisahan data *train-test*, serta parameter *training* model. Perancangan ini bertujuan agar sistem yang dibangun dapat menangani tantangan deteksi stomata pada citra yang telah ditingkatkan kualitasnya secara efektif.
5. Hasil rancangan sistem kemudian diimplementasikan menggunakan bahasa pemrograman *Python* dengan bantuan pustaka pendukung seperti *OpenCV* untuk pengolahan citra dan *PyTorch* atau *Ultralytics* untuk pemodelan *YOLOv11*. Modul-modul yang dibangun meliputi tahapan *preprocessing* (*Gamma Correction* dan *CLAHE*), pelatihan model *YOLOv11* menggunakan data set hasil peningkatan citra, serta sistem evaluasi untuk mengukur performa deteksi. Proses implementasi dilakukan secara bertahap dan modular untuk memudahkan *debugging* serta pengembangan lebih lanjut.
6. Sistem yang telah dikembangkan selanjutnya diuji menggunakan data uji yang telah disiapkan sebelumnya. Pengujian dilakukan dengan tujuan untuk mengevaluasi performa model dalam mendeteksi dan mengklasifikasikan stomata dari citra hasil praproses. Evaluasi dilakukan menggunakan metrik seperti *accuracy*, *precision*, *recall*, *F1-score*, dan *mean Average Precision* (*mAP*). Hasil dari pengujian ini digunakan untuk menilai efektivitas penerapan *Gamma Correction* dan *CLAHE* terhadap peningkatan performa deteksi menggunakan *YOLOv11*.
7. Tahap evaluasi dilakukan untuk menganalisis apakah sistem yang dibangun telah mencapai target performa yang diinginkan. Jika hasil pengujian menunjukkan performa yang belum optimal, maka dilakukan revisi pada tahap perancangan sistem atau proses pelatihan ulang dengan parameter yang disesuaikan. Evaluasi ini penting untuk memastikan bahwa sistem deteksi stomata yang dibangun benar-benar efektif dalam kondisi nyata dan tidak hanya unggul dalam lingkungan pengujian yang terbatas.
8. Tahap akhir dari proses penelitian ini adalah penyusunan laporan secara sistematis dan menyeluruh. Laporan mencakup latar belakang, rumusan masalah, studi literatur, metodologi penelitian, implementasi sistem, hasil pengujian, evaluasi, dan kesimpulan. Laporan disusun sesuai dengan format penulisan ilmiah yang berlaku sebagai dokumen pertanggungjawaban dari proses dan hasil penelitian yang telah dilakukan.

2.3 Sumber Data

Sumber data yang digunakan dalam penelitian ini adalah citra mikrograf stomata yang diperoleh menggunakan kamera digital yang terpasang pada mikroskop cahaya di Laboratorium AIMP, Universitas Hasanuddin. Data ini digunakan untuk mengklasifikasikan stomata daun dengan bantuan metode *deep learning*. Citra dari

kamera ini kemudian diolah menggunakan teknik *Gamma Correction* dan *CLAHE* untuk meningkatkan kualitas visual sebelum diproses oleh model *YOLOv11*. Data dikumpulkan secara langsung di laboratorium serta didukung oleh data set sekunder dari sumber terbuka sebagai bagian dari proses pelatihan dan pengujian sistem.

2.4 Perangkat Penelitian

1. Spesifikasi Perangkat Keras (*Lenovo Legion 5 Pro 16*)
   a. *NVIDIA RTX 4070 8 GB*
   b. *Intel Core i9 13900HX*
   c. *RAM 64 GB*
   d. *SSD 2 TB*
2. Perangkat Lunak
   a. Sistem Operasi Windows 11-64 bit
   b. Bahasa Pemrograman Python
   c. Jupyter Notebook
   d. Roboflow
   e. Microsoft Office

2.5 Rancangan Sistem

Alur perancangan sistem pada penelitian ini ditunjukkan pada gambar berikut ini:

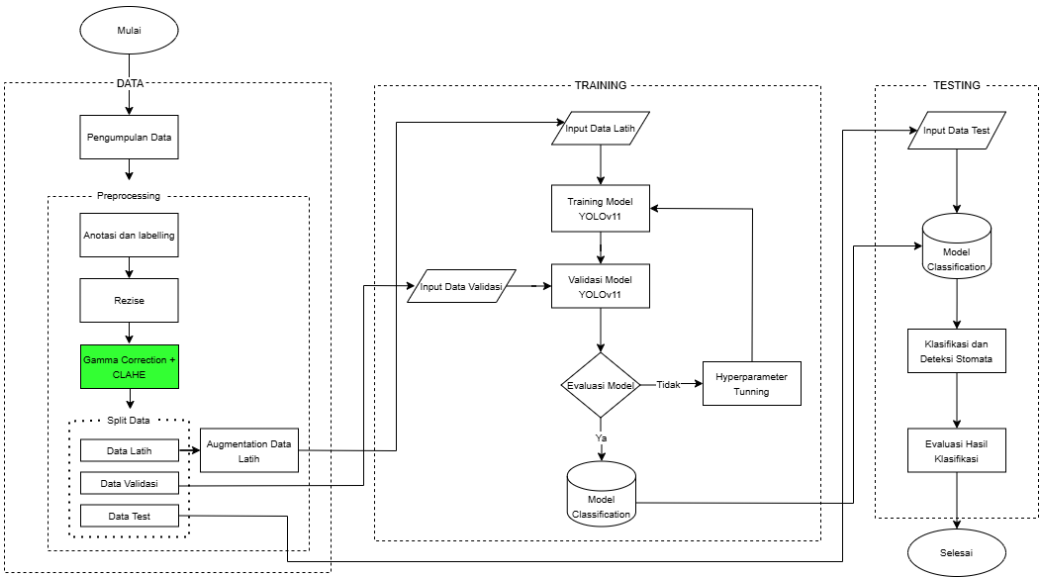

Gambar 7. Rancangan Sistem

Berdasarkan gambar 7 rancangan sistem, proses dilakukan sesuai alur yang telah dirancang untuk mencapai tujuan klasifikasi stomata yang diuraikan sebagai berikut:

2.5.1 Pengumpulan Data

Data dikumpulkan dalam bentuk citra mikrograf stomata dari daun tanaman yang diperoleh menggunakan kamera digital yang terpasang pada mikroskop cahaya. Proses pengambilan data dapat dilihat pada gambar 8.

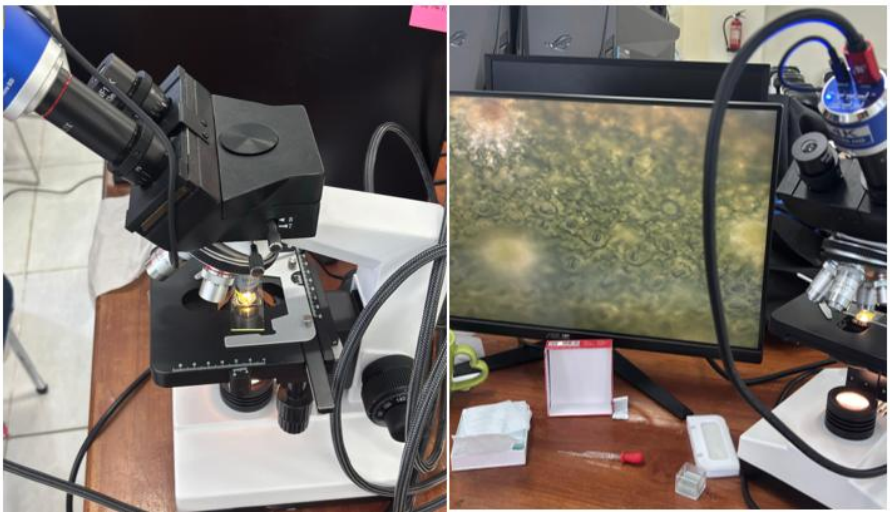

Gambar 8. Proses Pengambilan Data

2.5.2 *Preprocessing*

a. Anotasi dan *Labeling*

Setelah data citra dikumpulkan, dilakukan proses anotasi dengan menandai letak stomata menggunakan *bounding box* dan memberikan label berdasarkan jenis atau morfologi stomata seperti yang ada pada gambar 9. Tahap ini penting agar model *YOLOv11* dapat belajar mengenali dan membedakan jenis stomata berdasarkan posisi dan klasifikasinya.

Gambar 9. Proses Anotasi Labelling

b. *Rezise*

Citra yang telah dianotasi kemudian diubah ukurannya (*resize*) ke dimensi standar *YOLOv11*, seperti 640x640 piksel. Selanjutnya, citra diproses menggunakan *Gamma Correction* dan *CLAHE* untuk meningkatkan kontras dan kecerahan agar struktur stomata lebih terlihat jelas.

2.5.3 Gamma Correction

Sebelum proses deteksi dilakukan, citra uji terlebih dahulu diproses menggunakan *gamma correction* untuk meningkatkan kecerahan (*brightness*) akibat optik mikroskop. Tujuan dari tahap ini adalah untuk meningkatkan cahaya struktur stomata agar dapat dikenali lebih akurat oleh model.

e. Ambil nilai intensitas piksel asli

Tahap ini menunjukkan matriks nilai piksel asli dari kanal *green* citra berukuran 3×3. Setiap elemen merepresentasikan tingkat kecerahan warna hijau pada skala 0–255. Nilai tinggi (misalnya 255) menunjukkan piksel terang, sedangkan nilai rendah (misalnya 30) menunjukkan piksel gelap.

$$\boldsymbol{G} = \begin{bmatrix} \mathbf{200} & \mathbf{150} & \mathbf{100} \\ \mathbf{50} & \mathbf{128} & \mathbf{220} \\ \mathbf{30} & \mathbf{180} & \mathbf{255} \end{bmatrix} \tag{2}$$

f. Normalisasi nilai piksel

Setiap nilai piksel dibagi dengan 255 agar berada pada rentang 0–1. Langkah ini penting karena banyak operasi pemrosesan citra—termasuk *Gamma Correction* bekerja lebih stabil pada domain ter-normalisasi, dengan rumus:

$$\boldsymbol{I_{out}} = \frac{\boldsymbol{I_{in}}}{\mathbf{255}} \tag{3}$$

Maka hasil normalisasi:

$$\boldsymbol{I_{out}} = \begin{bmatrix} \mathbf{0.784} & \mathbf{0.588} & \mathbf{0.392} \\ \mathbf{0.196} & \mathbf{0.502} & \mathbf{0.863} \\ \mathbf{0.118} & \mathbf{0.706} & \mathbf{1.000} \end{bmatrix} \tag{4}$$

g. Terapkan rumus *Gamma Correction*

Rumus $I_{out} = I_{in}{}^{\mathrm{y}}$ digunakan untuk memperbaiki kecerahan citra. Karena nilai $\gamma = 1.5 > 1$, hasilnya membuat piksel gelap menjadi lebih gelap dan piksel terang sedikit lebih cerah. Proses ini menyesuaikan distribusi intensitas agar detail pada area terang lebih menonjol, maka:

$$\boldsymbol{I_{out}} = \boldsymbol{I_{in}}{}^{\mathbf{1.5}} \tag{5}$$

Hasilnya:

$$\boldsymbol{I_{out}} = \begin{bmatrix} (\mathbf{0.784})^{1.5} & (\mathbf{0.588})^{1.5} & (\mathbf{0.392})^{1.5} \\ (\mathbf{0.196})^{1.5} & (\mathbf{0.502})^{1.5} & (\mathbf{0.863})^{1.5} \\ (\mathbf{0.118})^{1.5} & (\mathbf{0.706})^{1.5} & (\mathbf{1.000})^{1.5} \end{bmatrix} \tag{6}$$

$$= \begin{bmatrix} \mathbf{0.693} & \mathbf{0.451} & \mathbf{0.245} \\ \mathbf{0.087} & \mathbf{0.356} & \mathbf{0.802} \\ \mathbf{0.041} & \mathbf{0.593} & \mathbf{1.000} \end{bmatrix} \tag{7}$$

h. Kembalikan ke skala 0–255

Setelah proses *Gamma Correction* selesai, hasil yang semula dalam rentang 0–1 dikembalikan ke skala intensitas citra asli dengan mengalikan 255:

$$\boldsymbol{I_{out}} = \boldsymbol{I_{in}} \times \mathbf{255} \tag{8}$$

Sehingga hasil akhirnya:

$$\boldsymbol{I_{out}} = \begin{bmatrix} \mathbf{177} & \mathbf{115} & \mathbf{62} \\ \mathbf{22} & \mathbf{91} & \mathbf{204} \\ \mathbf{10} & \mathbf{151} & \mathbf{255} \end{bmatrix} \tag{9}$$

2.5.4 CLAHE (*Contrast Limited Adaptive Histogram Equalization)*

Setelah melalui proses perbaikan kecerahan, citra uji kemudian diproses menggunakan *CLAHE* untuk meningkatkan kontras warna (*color contrast*). Tujuan dari tahap ini adalah untuk meningkatkan warna struktur stomata agar dapat dikenali lebih akurat oleh model.

a. Menghitung Histogram

Histogram dibuat dengan menghitung frekuensi kemunculan setiap nilai intensitas pada matriks keluaran I. Karena matriks 3×3 berisi sembilan nilai unik (10, 22, 62, …, 255) dan masing-masing muncul satu kali, tabel histogram menunjukkan frekuensi 1 untuk setiap nilai. Histogram ini memberi gambaran distribusi intensitas di kasus ini distribusi sangat jarang karena semua nilai unik.

$$\boldsymbol{I} = \begin{bmatrix} \mathbf{177} & \mathbf{115} & \mathbf{62} \\ \mathbf{22} & \mathbf{91} & \mathbf{204} \\ \mathbf{10} & \mathbf{151} & \mathbf{255} \end{bmatrix} \tag{10}$$

Tabel 2. Nilai Histogram

Nilai Intensitas (I)	Frekuensi (P)
10	1
22	1
62	1
91	1
115	1
151	1
177	1
204	1
255	1

b. Hitung *CDF* (*Cumulative Distribution Function*)

CDF diperoleh dengan melakukan akumulasi frekuensi histogram dari nilai intensitas terendah ke tertinggi. Untuk tiap nilai I, *CDF*(I) adalah jumlah frekuensi semua intensitas $\leq I$. Karena tiap nilai frekuensinya 1, *CDF* bertambah satu tiap baris: 1, 2, 3, …, 9. *CDF* menunjukkan proporsi kumulatif piksel sampai ambang tertentu dan digunakan untuk meratakan atau meregangkan distribusi intensitas.

Tabel 3. Nilai *CDF*

I	P	*CDF*
10	1	1
22	1	2
62	1	3
91	1	4
115	1	5
151	1	6
177	1	7
204	1	8
255	1	9

c. Normalisasi *CDF* (Manual *CLAHE*)

Normalisasi CDF (Manual *CLAHE*) rumus dan maknanya (Persamaan 11 dan Tabel 3), rumus *CLAHE* manual yang digunakan adalah:

$$\boldsymbol{I}_{\text{baru}} = \frac{(\text{CDF}(\boldsymbol{I}) - \text{CDF}_{\boldsymbol{min}})}{(\boldsymbol{N} - \text{CDF}_{\boldsymbol{min}})}\ (\boldsymbol{L} - \mathbf{1}) \tag{11}$$

Dimana:

$\mathbf{I}_{\text{baru}}$: Nilai intensitas baru setelah peningkatan kontras.

CDF(I): Nilai kumulatif histogram pada intensitas Idi dalam satu blok.

CDF_{min}: Nilai CDF terkecil pada blok tersebut sebagai acuan normalisasi.

N: Jumlah total piksel dalam blok (*tile*).

L: Jumlah level intensitas.

Dengan $L = 256,\ N = 9,\ \text{CDF}_{min} = 1$

Rumus ini memetakan nilai *CDF* ke rentang 0–255 secara linier; mengurangi CDF_{min}*m*enghindari pemetaan semua nilai ke 0 jika CDF terendah bukan nol. Hasilnya adalah nilai baru untuk setiap intensitas input yang bertujuan menyebarkan kembali intensitas sehingga kontras lokal meningkat. Tabel 3 menunjukkan hasil pemetaan *CDF* ke nilai baru (misalnya CDF=2 → 32, CDF=5 → 128, dst).

Tabel 4. Nilai Hasil Perhitungan *CLAHE*

I	P	*CDF*	Nilai Baru
10	1	1	0
22	1	2	32
62	1	3	64
91	1	4	96
115	1	5	128
151	1	6	160
177	1	7	192
204	1	8	224
255	1	9	255

d. Terapkan Nilai Baru ke Matriks Awal

Setiap elemen pada matriks intensitas awal digantikan dengan nilai baru sesuai tabel pemetaan *CLAHE* sehingga terbentuk matriks hasil:

$$\boldsymbol{G} = \begin{bmatrix} \mathbf{192} & \mathbf{128} & \mathbf{64} \\ \mathbf{32} & \mathbf{96} & \mathbf{224} \\ \mathbf{0} & \mathbf{160} & \mathbf{255} \end{bmatrix} \tag{12}$$

Langkah ini menghasilkan citra dengan kontras yang diregangkan: area gelap menjadi lebih gelap (misalnya 10 → 0) dan area terang dipertegas (misalnya 255 tetap

255), sehingga perbedaan antara tingkat intensitas menjadi lebih jelas dan detail lokal lebih terlihat.

2.5.5 *Split Data*

Data set kemudian dibagi menjadi tiga bagian yaitu data latih untuk proses pelatihan model, data validasi untuk mengevaluasi performa model selama pelatihan, dan data uji untuk mengukur performa akhir model. Pembagian ini dilakukan secara proporsional untuk mencegah *overfitting* dan meningkatkan generalisasi model terhadap data baru. Pada tabel 5 dipaparkan pembagian dataset, dan tabel 6 menampilkan hasil jumlah label dataset.

Tabel 5. *Split* Dataset

Class	***Train***
Train	1164
Valid	325
Test	174
Total	1663

Tabel 6. Distribusi Label Dataset

Class	***Train***	***Valid***	***Test***	**Total**
Anomocytic	6773	1303	513	8589
Diacytic	14158	3111	896	18165
Graminoid	5992	1276	664	8232
Paracytic	13571	2291	1688	17550
Total	40494	7981	3761	52236

2.5.6 Augmentasi Data Latih

Untuk menambah jumlah dan variasi data latih, dilakukan augmentasi citra. Teknik augmentasi yang digunakan meliputi rotasi dan *flipping* (pencerminan). Tahapan ini bertujuan untuk membuat model lebih tangguh terhadap perubahan posisi dan pencahayaan saat mendeteksi stomata pada kondisi yang berbeda. Setelah di augmentasi dataset *train* menjadi 3374 dari 1164. Dengan distribusi yang dipaparkan pada tabel 7.

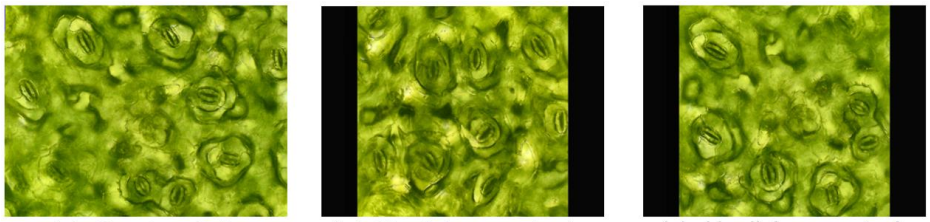

(a) Gambar Asli (b) Hasil Augmentasi *Rotate* (c) Hasil Augmentasi *Flipping*

Gambar 10. Penerapan *Augmentasi*

Tabel 7. Distribusi *Augmentasi* Data *Training*

Class	***Train***
Anomocytic	12823
Diacytic	28780
Graminoid	11683
Paracytic	26004
Total	**79290**

2.5.7 *Input* Data Training

Data latih yang telah melalui proses *augmentasi* dan *preprocessing* dimasukkan ke dalam proses pelatihan model *YOLOv11*. Model akan mempelajari fitur visual dari stomata berdasarkan *bounding box* dan label yang telah ditentukan, sehingga mampu melakukan klasifikasi stomata secara otomatis dengan tingkat akurasi yang tinggi.

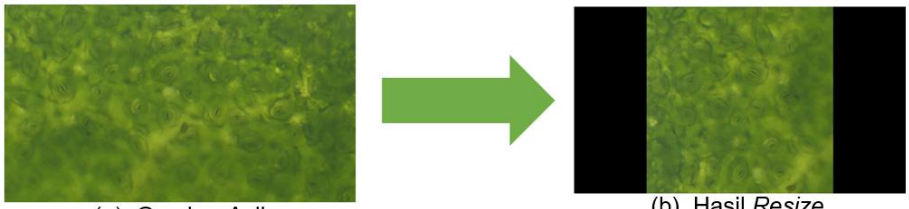

(a) Gambar Asli (b) Hasil *Resize*

Gambar 11. Inputan YOLOv11

Citra masukan berukuran 640 × 640 × 3 (RGB). Setiap piksel dinormalisasi ke rentang [0,1] menggunakan persamaan:

$$\boldsymbol{I_{norm}} = \frac{\boldsymbol{I_{rgb}}}{\mathbf{255}} \tag{13}$$

Misal pada satu piksel di koordinat (0,0) memiliki nilai

$R = 120, \quad G = 200, \quad B = 150$

Maka hasil normalisasinya:

$\mathrm{R} = 0.47, \mathrm{G} = 0.78, \mathrm{B} = 0.59$

2.5.8 *Training* Model *YOLOv11*

Model *YOLOv11* mulai dilatih menggunakan data latih. Pada tahap ini, model mempelajari fitur visual dari stomata, termasuk bentuk, struktur, dan pola distribusinya, agar mampu mendeteksi dan mengklasifikasikan stomata secara otomatis.

a. Lapisan Konvolusi

Proses konvolusi, yang berfungsi untuk mengekstraksi fitur-fitur penting dari citra masukan. Lapisan pertama YOLOv11 melakukan konvolusi 3 kanal menjadi 32

fitur dengan *kernel* 3×3, *stride* 2, dan *padding* 1.
Rumus konvolusi:

$$\mathbf{Y(i,j,k) = \Sigma\Sigma\Sigma W_{m,n,c,k} * X_{i+m,j+n,c} + b_k} \quad (14)$$

Dimana:

$Y(i,j,k)$: Output fitur pada posisi (i,j), kanal k

X: Nilai piksel input

W: Bobot kernel

(m,n,c): Indeks posisi kernel dan kanal input

$\sum$: Penjumlahan seluruh elemen kernel

b_k: Bias kanal keluaran k

Contoh perhitungan pada fitur pertama (k=0): misal bobot *kernel* rata-rata W=0.1 dan bias b=0.05,

$$\mathbf{Y(0,0,0) = 0.1 \times (0.47 + 0.78 + 0.59) + 0.05 = 0.234} \quad (15)$$

Hasil aktivasi (*SiLU*):

$$\mathbf{f(Y) = Y \times \sigma(Y) = 0.234 \times \frac{1}{1 + e^{-0.234}} = 0.234 \times 0.558 = 0.130} \quad (16)$$

Ukuran keluaran menjadi 320 × 320 × 32.

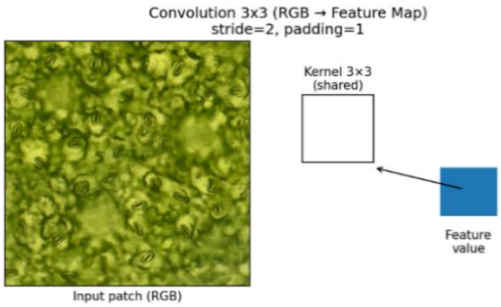

Gambar 12. Proses Konvolusi

b. Blok C3k2F

Setelah konvolusi dasar, *YOLOv11* menggunakan blok residual untuk mempertahankan informasi dari lapisan sebelumnya dan mempercepat proses konvergensi. Blok *C3k2F* terdiri dari dua konvolusi berurutan dan *shortcut*:

$$\mathbf{O = f(W2 * f(W1 * X)) + X} \quad (17)$$

Dimana:
X: Input blok

$W1, W2$: Bobot konvolusi pertama dan kedua

f: Fungsi aktivasi (SiLU)

$*$: Operasi konvolusi

O: Output blok residual

$+X$: Shortcut / skip-connection untuk menjaga informasi awal

Misal hasil f(W_1 * X) = 0.13 dan f(W_2 * X) = 0.40, maka:

$$\mathbf{O} = \mathbf{0.40} + \mathbf{0.13} = \mathbf{0.53} \tag{18}$$

Ukuran tetap 320 × 320 × 32.

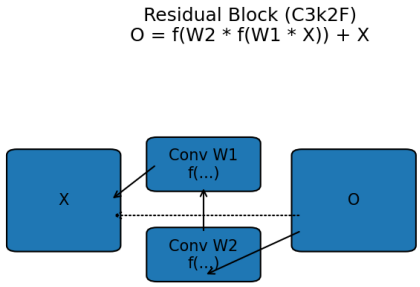

Gambar 13. Proses Blok C3k2F

c. Blok C3k2T

Tahapan ini bertujuan memperkaya representasi fitur dengan menambah jumlah kanal. Blok ini meningkatkan kedalaman fitur menjadi 64 kanal:

$$\mathbf{O_T} = \mathbf{f}(\mathbf{W_T} * \mathbf{O}) \tag{19}$$

Dimana:

X: Input dari blok sebelumnya

W_T: Bobot konvolusi untuk penambahan kanal

$*$: Operasi konvolusi

f: Fungsi aktivasi (SiLU)

O_T: Output fitur dengan kanal yang ditingkatkan

Misal bobot rata-rata$W_T = 0.5$, maka:

$$\mathbf{O_T = 0.5 \times 0.53 = 0.265} \tag{20}$$

Ukuran *output* 160 × 160 × 64.

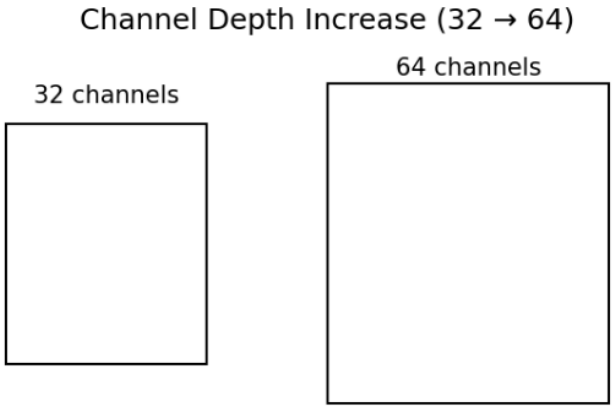

Gambar 14. Proses Blok C3k2T

d. Blok *SPPF* (*Spatial Pyramid Pooling - Fast*)

Lapisan *SPPF* digunakan untuk menangkap informasi konteks dari berbagai skala tanpa mengubah ukuran input. *SPPF* menggabungkan informasi multi-skala dengan *pooling* 5×5, 9×9, dan 13×13:

$$\mathbf{O_s ppf = Concat\big(P_5(O_T), P_9(O_T), P_13(O_T)\big)} \tag{21}$$

Misal hasil pooling rata-rata:

$$\mathbf{P_5 = 0.26, P_9 = 0.27, P_{13} = 0.29} \tag{22}$$

Dimana:

O_T: Input dari blok sebelumnya

P_5, P_9, P_{13}: Pooling dengan ukuran kernel 5×5, 9×9, dan 13×13

Concat : Menggabungkan hasil pooling multi-skala

O_{sppf}: Output fitur multi-skala dari blok SPPF

Maka:

$$\mathbf{O_{sppf} = [0.26, 0.27, 0.29] = 0.27} \tag{23}$$

Ukuran output menjadi 80 × 80 × 128.

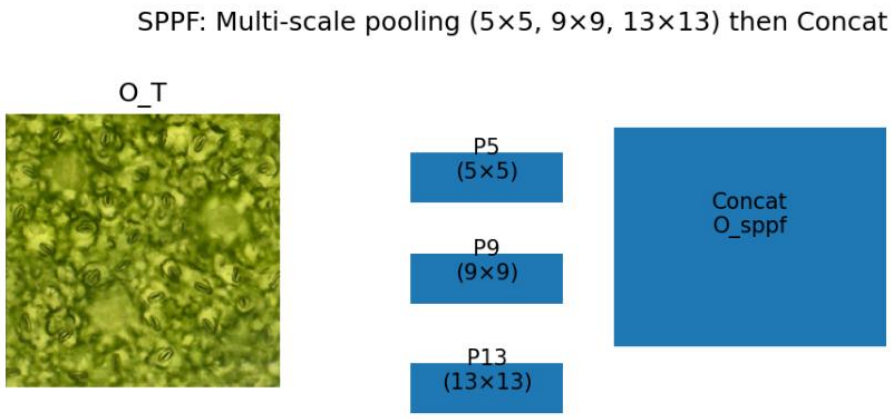

Gambar 15. Proses Blok SPPF

e. Blok C2PSA (*Cross Stage Partial Spatial Attention*)

Mekanisme perhatian bekerja dengan menekankan area penting pada peta fitur dan menekan area yang tidak relevan. *C2PSA* menerapkan mekanisme perhatian spasial dan kanal dengan persamaan:

$$\mathbf{A} = \boldsymbol{\sigma}\left(\mathbf{W_a} * \mathbf{O_{ssppf}}\right) \tag{24}$$

$$\mathbf{O_{c2psa}} = \mathbf{A} \odot \mathbf{O_{sppf}} \tag{25}$$

Dimana:
O_{sppf}: Input dari blok SPPF

W_a: Bobot konvolusi untuk menghasilkan peta perhatian

$*$: Operasi konvolusi

σ: Fungsi sigmoid untuk normalisasi perhatian

A: Peta perhatian (attention map)

$\odot$: Perkalian elemen-per-elemen

O_{c2psa}: Output setelah perhatian diterapkan

$\mathrm{W_a} = 0.7$ Maka

$$\mathbf{A} = \boldsymbol{\sigma}(\mathbf{0.7} \times \mathbf{0.27}) = \boldsymbol{\sigma}(\mathbf{0.189}) = \mathbf{0.547} \tag{26}$$

$$\mathbf{O_{c2psa}} = \mathbf{0.547} \times \mathbf{0.27} = \mathbf{0.148} \tag{27}$$

Ukuran tetap 80 × 80 × 128.

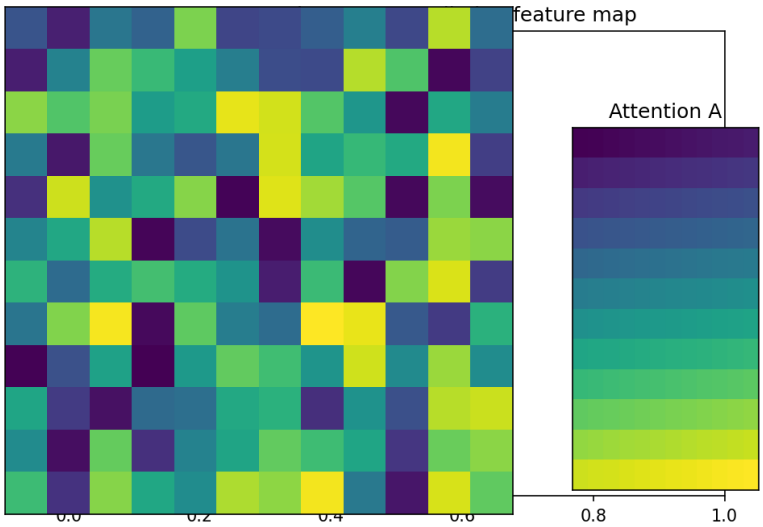

Gambar 16. Proses Blok C2PSA

f. *Upsample* dan *Concat*

Setelah fitur diperoleh dari berbagai lapisan, *YOLOv11* melakukan fusi menggunakan mekanisme upsample dan concatenate. Tujuannya agar informasi spasial (resolusi tinggi) dari lapisan bawah dan informasi semantik (abstraksi tinggi) dari lapisan atas dapat digabung.

Upsample menggandakan resolusi:

$$\mathbf{O_{up}} = \mathbf{Interp}\left(\mathbf{O_{c2psa}}, \mathbf{2} \times\right) \rightarrow \mathbf{160} \times \mathbf{160} \times \mathbf{128} \tag{28}$$

Kemudian di-*concat* dengan fitur dari tahap sebelumnya:

$$\mathbf{O_{concat}} = \left[\mathbf{O_{up}}, \mathbf{O_T}\right] \tag{29}$$

Ukuran hasil 160 × 160 × 192.

Pada YOLOv11, proses *Concat* dan *Upsample* dilakukan secara multi-skala untuk menggabungkan fitur dari tiga tingkat resolusi berbeda, yaitu:

- 80×80 (skala besar, mendeteksi objek kecil),
- 40×40 (skala menengah),
- 20×20 (skala kecil, mendeteksi objek besar).

Dengan cara ini, model dapat mendeteksi stomata pada berbagai ukuran dan posisi di permukaan daun.

g. Lapisan Deteksi

Tahap ini adalah inti dari proses prediksi YOLOv11. Setiap grid sel pada peta keluaran memprediksi koordinat kotak pembatas (bounding box), tingkat kepercayaan (objectness), dan probabilitas kelas.

Layer deteksi menggunakan *kernel* 1×1 untuk menghasilkan prediksi kotak:

$$\boldsymbol{Z = W_d * O_{concat} + b_d} \tag{30}$$

Misal $W_d = 0.3, b_d = 0.05$:

$$\boldsymbol{Z = 0.3 \times 0.148 + 0.05 = 0.094} \tag{31}$$

Setiap skala (80×80, 40×40, 20×20) menghasilkan prediksi dengan format:

$$\boldsymbol{P = (\sigma(x), \sigma(y), \sigma(w), \sigma(h), \sigma(obj), p1, p2, \dots, pn)} \tag{32}$$

dimana:

(x, y): koordinat pusat *bounding box*,

(w, h): ukuran kotak prediksi,

obj: *confidence* bahwa terdapat objek,

p_i : probabilitas tiap kelas stomata.

Tiga *output head* ini kemudian digabungkan untuk menghasilkan hasil deteksi akhir pada berbagai skala.

h. Dekode *Bounding Box*

Setelah prediksi dihasilkan, YOLOv11 melakukan tahap dekode untuk mengonversi koordinat prediksi ke posisi sebenarnya dalam citra. Bounding box divisualisasikan dalam bentuk persegi panjang yang menunjukkan lokasi dan ukuran objek. *YOLOv11* mendekode keluaran jaringan $(\mathrm{t_x}, \mathrm{t_y}, \mathrm{t_w}, \mathrm{t_h})$ menjadi koordinat objek dalam citra asli.

Rumus dekode:

$$\boldsymbol{b_x = \frac{2\sigma(t_x) - 0.5 + c_x}{S}}, \ \boldsymbol{b_y = \frac{2\sigma(t_y) - 0.5 + c_y}{S}} \tag{33}$$

$$\boldsymbol{b_w = \left(2\sigma(t_w)\right)^2 \times a_w}, \ \boldsymbol{b_h = \left(2\sigma(t_h)\right)^2 \times a_h} \tag{34}$$

Dengan $t_x = t_y = t_w = t_h = 0.094, \ a_w = a_h = 20, \ S = 80, \ c_x = c_y = 5$

$$\boldsymbol{\sigma(0.094) = 0.523} \tag{35}$$

Sehingga

$$\boldsymbol{b_x = \frac{2(0.523) - 0.5 + 5}{80} = 0.069}, \boldsymbol{b_y = 0.069} \tag{36}$$

$$\boldsymbol{b_w = (1.046)^2 \times 20 = 21.9}, \ \boldsymbol{b_h = 21.9} \tag{37}$$

Konversi ke ukuran asli (640x640):

$$\boldsymbol{X}_{\text{pusat}} = \mathbf{0.069} \times \mathbf{640} = \mathbf{44.2}, \tag{38}$$

$$\boldsymbol{Y}_{\text{pusat}} = \mathbf{0.069} \times \mathbf{640} = \mathbf{44.2} \tag{39}$$

Artinya:

YOLOv11 memprediksi terdapat objek stomata dengan pusat di koordinat (44, 44) dan ukuran sekitar 22×22 piksel pada citra beresolusi 640×640.

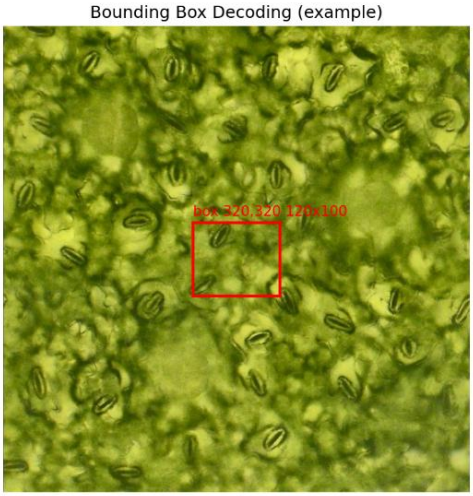

Gambar 17. *Bounding Box Decoding*

i. *Output* Klasifikasi (Jenis Stomata)

Setelah lokasi objek diperoleh, YOLO menghitung skor kelas untuk menentukan tipe stomata:

$$\mathbf{p_i} = \boldsymbol{\sigma}(\mathbf{W_i} * \mathbf{Z} + \mathbf{b_i}) \tag{40}$$

Misalkan model memiliki empat kelas: Anomositik, Parasitik, Diasitik, dan Graminoid.
Hasil prediksi (logit) dari layer deteksi: $\mathrm{Z} = [0.094, 0.35, 0.72, 0.56]$

Nilai $\mathrm{Z}_1 = 0.094$ diperoleh dari perhitungan konvolusi terakhir:

$$\mathbf{Z_1} = \mathbf{0.3}(\mathbf{0.148}) + \mathbf{0.05} = \mathbf{0.094} \tag{41}$$

Sementara nilai $\mathrm{Z}_2 = 0.35, \mathrm{Z}_3 = 0.72, \mathrm{dan} \mathrm{Z}_4 = 0.56$ diperoleh dengan rumus yang sama menggunakan bobot dan bias berbeda untuk tiap kelas.

Setelah fungsi sigmoid:

$$\boldsymbol{p} = [\boldsymbol{\sigma}(\mathbf{0.094}), \boldsymbol{\sigma}(\mathbf{0.35}), \boldsymbol{\sigma}(\mathbf{0.72}), \boldsymbol{\sigma}(\mathbf{0.56})] = [\mathbf{0.523}, \mathbf{0.586}, \mathbf{0.673}, \mathbf{0.636}] \qquad (42)$$

Kelas dengan nilai probabilitas tertinggi adalah kelas ke 3 (diasitik) dengan 67.3%. Jika pada kondisi lain nilai tertinggi muncul pada kelas ke 4 (graminoid, maka hasil akhir akan ditanyakan sebagai stomata tipe Geaminoid.

Artinya:

YOLOv11 memprediksi terdapat objek stomata berjenis Diasitik dengan pusat koordinat (44,44), ukuran 22 x 22 piksel, dan tingkat keyakinan 67.3%.

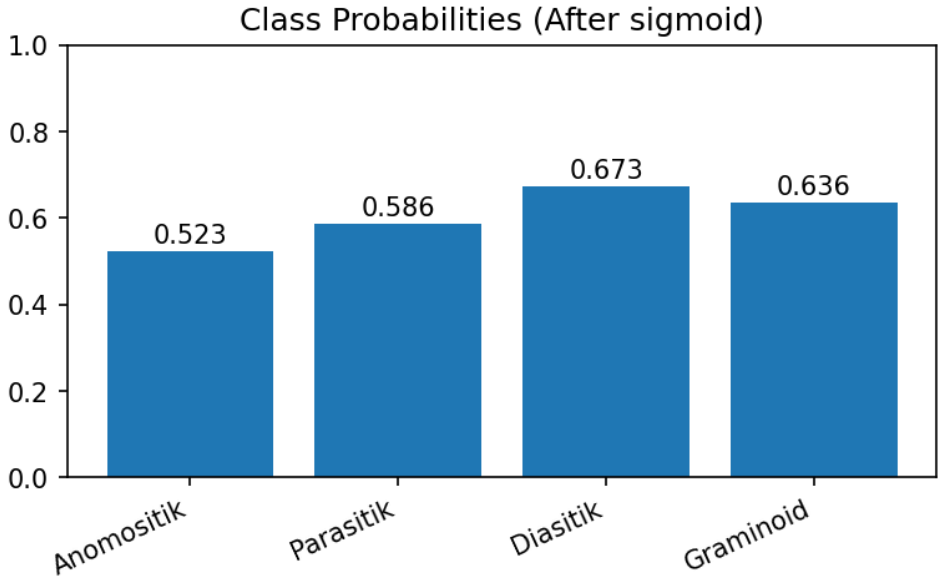

Gambar 18. Probabilitas Kelas

Semua nilai probabilitas kelas diperoleh dari perhitungan fungsi sigmoid terhadap logit hasil konvolusi akhir, sedangkan nilai nilai Z_2, Z_3, Z_4 dihitung dengan rumus yang sama seperti contoh Z_1 di atas.

2.5.9 *Input* Data Validasi

Data validasi digunakan sebagai referensi untuk menilai kinerja model secara objektif selama proses pelatihan. Untuk memastikan bahwa model tidak belajar dari data pelatihan, data validasi dalam penelitian ini terdiri dari sekumpulan gambar stomata yang terpisah dari data pelatihan. sehingga hasil prediksi yang dihasilkan benar-benar menunjukkan kemampuan model untuk menangani data baru. Data validasi dimasukkan secara berkala pada setiap interval waktu selama penelitian untuk mengamati tren performa model, termasuk peningkatan akurasi dan penurunan nilai kehilangan. Dengan menganalisis hasil validasi ini, para peneliti dapat mengidentifikasi kemungkinan overfitting, underfitting, atau indikasi bahwa parameter perlu disesuaikan pada tahap pelatihan berikutnya. Dengan demikian, data validasi memainkan peran penting dalam

menjamin bahwa model yang dilatih mampu beradaptasi dengan pola visual stomata secara lebih umum dan tidak hanya menghafal data pelatihan.

2.5.10 Validasi Model *YOLOv11*

Setelah pelatihan selesai, model YOLOv11 diuji dengan data validasi yang telah disiapkan sebelumnya. Proses validasi dilakukan untuk mendapatkan gambaran awal tentang stabilitas dan kemampuan generalisasi model untuk mendeteksi dan mengklasifikasikan berbagai jenis stomata. Hasil prediksi model dinilai berdasarkan tingkat ketepatan deteksi, kesesuaian bounding box, dan konsistensi pengenalan pola morfologi stomata. Selain itu, proses validasi memastikan apakah model telah mempelajari fitur visual yang relevan, seperti bentuk sel tetangga. Dengan menggunakan *YOLOv11*, peneliti dapat memanfaatkan peningkatan arsitektur pada versi terbaru dari *YOLO* untuk memperoleh performa validasi yang lebih baik, terutama dalam hal akurasi deteksi objek berukuran kecil seperti stomata.

2.5.11 Evaluasi Model

Dalam proses evaluasi model, sejumlah metrik standar digunakan, termasuk precision, recall, dan mean average precision (mAP). Precision mengukur tingkat ketepatan model dalam mengidentifikasi objek stomata tanpa menghasilkan deteksi palsu, sedangkan recall mengukur kemampuan model dalam menemukan seluruh objek stomata yang benar-benar ada. Karena mAP memperhitungkan nilai presisi pada berbagai ambang batas Intersection over Union (IoU), itu digunakan sebagai indikator kinerja lengkap. Hasil evaluasi selama penelitian menunjukkan perbedaan dalam kinerja setiap kelas stomata. Ini memungkinkan peneliti untuk menentukan kelas mana yang memerlukan perhatian lebih lanjut. Analisis yang lebih mendalam terhadap hasil evaluasi juga membantu menemukan kemungkinan kelemahan model, seperti kesalahan klasifikasi pada bentuk stomata yang memiliki morfologi yang sangat mirip atau kerusakan kualitas gambar pada objek. Hasil ini kemudian digunakan oleh peneliti untuk melakukan optimasi lanjutan pada tahap tunning hyperparameter.

2.5.12 *Hyperparameter Tuning*

Berdasarkan hasil evaluasi, peneliti kemudian melakukan penyesuaian hyperparameter untuk meningkatkan kinerja model. Beberapa parameter penting dalam arsitektur YOLOv11 telah disesuaikan, termasuk ukuran batch (ukuran batch = 32), dan jumlah epoch (100 epoch). Tujuan dari proses tuning ini adalah untuk mencapai konfigurasi terbaik yang memungkinkan model mempelajari fitur visual stomata dengan lebih baik tanpa mengalami overfitting. Selama penelitian, sejumlah kombinasi parameter diuji secara bertahap untuk mengevaluasi pengaruh mereka terhadap stabilitas hasil prediksi, akurasi deteksi, dan nilai kehilangan. Model dapat meningkatkan nilai precision, recall, dan mAP dengan penyesuaian hyperparameter yang cermat. Selain itu, proses tunning membantu generalisasi model ketika diuji menggunakan data stomata yang lebih bervariasi.

2.5.13 Model *Classification*

Model YOLOv11 ditetapkan sebagai model terakhir dan hasil pelatihan YOLOv11 disimpan dalam format.pt, yang akan digunakan pada tahap analisis berikutnya. Proses pelatihan selesai ketika hasil memenuhi kriteria. Pada saat ini, model dianggap stabil dan

mampu membuat prediksi yang akurat tentang cara menemukan stomata dan mengklasifikasikannya. Model terakhir inilah yang digunakan sebagai sistem prediksi utama penelitian ini. Selain itu, analisis kembali dilakukan pada model terakhir untuk memastikan bahwa bobot dan parameter yang tersimpan mencerminkan kinerja terbaik yang dicapai selama proses pelatihan. Oleh karena itu, model YOLOv11 terakhir telah siap digunakan untuk proses pengujian dengan menggunakan data yang benar-benar baru untuk menilai performa sebenarnya pada kondisi riil.

2.5.14 *Input* Data Testing

Data pengujian adalah sekumpulan gambar stomata yang tidak pernah digunakan dalam proses pelatihan atau validasi. Data tes digunakan dalam penelitian ini untuk menggambarkan performa akhir model dalam skenario nyata, yang menunjukkan perbedaan kondisi gambar mikroskopis. Variasi kualitas gambar, intensitas cahaya, orientasi objek, dan perbedaan jenis jaringan daun disertakan dalam data ini untuk memberikan pengujian yang lebih mendalam.

Pada titik ini, model akan melakukan sendiri untuk mendeteksi dan mengklasifikasikan stomata. Untuk menilai akurasi model di lapangan, hasil prediksi dibandingkan dengan label kebenaran (ground truth). Tahap ini sangat penting karena hasil tes menentukan keberhasilan model dalam menangani data yang kompleks dan bervariasi.

2.5.15 Klasifikasi dan Deteksi Stomata

Proses klasifikasi dan deteksi stomata menggunakan model YOLOv11 yang telah dipersiapkan adalah tahap terakhir dari penelitian ini. Pada titik ini, model dapat menghasilkan output seperti bounding box yang menunjukkan posisi objek, label kelas yang menunjukkan jenis stomata, dan nilai keyakinan yang menunjukkan tingkat keyakinan model terhadap prediksi yang dibuat. Model mengklasifikasikan stomata otomatis menjadi empat kategori: anomocytic, diacytic, paracytic, dan graminoid. Dalam penelitian ini, ditunjukkan bahwa penerapan model dapat mempercepat proses analisis dibandingkan dengan metode manual. Itu juga dapat meningkatkan konsistensi dan objektivitas identifikasi. Selanjutnya, hasil deteksi dan klasifikasi dipelajari untuk membantu memahami secara ilmiah perbedaan morfologi stomata dan tujuan penelitian.

2.5.16 Evaluasi Hasil Klasifikasi

Setelah deteksi dan klasifikasi stomata selesai, hasilnya dibandingkan dengan kebenaran aslinya—atau label sebenarnya—dan dinilai dengan beberapa metrik performa. Accuracy, precision, recall, F1-score, dan mean average precision (mAP) adalah metrik utama yang digunakan dalam penilaian ini. Tujuan dari evaluasi ini adalah untuk mengetahui seberapa akurat model dapat mendeteksi dan mengklasifikasikan stomata dari gambar mikrograf.

Digunakan teknik evaluasi matrix confusion untuk mengetahui seberapa baik model YOLOv11 mendeteksi berbagai jenis stomata pada masing-masing skenario pengolahan gambar—tanpa preprocessing, dengan koreksi Gamma, dan dengan CLAHE. Matrix confusion ini menunjukkan empat kategori utama biner atau multi-kelas, yaitu:

1. *True Positive* (TP): Objek stomata yang berhasil terdeteksi dan diklasifikasikan dengan benar oleh model.
2. *False Negative* (FN): Objek stomata yang tidak berhasil terdeteksi oleh model (*missed detection*).
3. *False Positive* (FP): Bagian citra non-stomata yang secara keliru terdeteksi sebagai stomata oleh model.
4. *True Negative* (TN): Bagian citra yang bukan stomata dan dengan benar tidak diklasifikasikan sebagai stomata oleh model.

		Nilai Aktual	
		Positive	**Negative**
Nilai Prediksi	**Positive**	TP	FP
	Negative	FN	TN

Gambar 19. *Confusion Matrix*

Source: https://medium.com/@sserafino5/panduan-tentang-matriks-konfusi-mengukur-akurasi-model-klasifikasi-ad76994f7b91

Gambar 19 merupakan evaluasi dengan *confusion matrix* digunakan karena merupakan pendekatan umum dalam pembelajaran *supervised learning*, yang berfungsi untuk memberikan gambaran kinerja dari model klasifikasi. Beberapa metrik turunan yang digunakan antara lain:

1. *Accuracy*, Menunjukkan tingkat keakuratan model secara keseluruhan dalam mengklasifikasikan citra. Rumusnya adalah.

$$\boldsymbol{Accuracy} = \frac{\boldsymbol{TP + TN}}{\boldsymbol{TP + TN + FP + FN}} \tag{43}$$

2. *Precision*, Mengukur seberapa banyak prediksi positif yang benar-benar merupakan stomata. *Precision* sangat penting ketika salah klasifikasi sebagai stomata perlu dihindari.

$$\boldsymbol{Precision} = \frac{\boldsymbol{TP}}{\boldsymbol{TP + FP}} \tag{44}$$

3. *Recall*, Menunjukkan kemampuan model dalam mendeteksi semua objek stomata yang ada. *Recall* penting ketika semua objek harus ditemukan, meskipun ada risiko deteksi palsu.

$$\boldsymbol{Recall} = \frac{\boldsymbol{TP}}{\boldsymbol{TP + FN}} \tag{45}$$

4. F1-Score, Merupakan rata-rata harmonis antara *Precision* dan *Recall*, yang berguna ketika diperlukan keseimbangan antara keduanya.

$$\boldsymbol{F1 - Score = 2 \,.\, \frac{TP}{TP + FN}} \tag{46}$$

5. *Mean Average Precision (mAP),* Rata-rata dari nilai AP untuk semua kelas. Ini digunakan dalam multi-class *classification* dan deteksi objek seperti *YOLO*.

$$\boldsymbol{mAP = \frac{1}{N}\sum_{i=1}^{N} AP_i} \tag{47}$$

Keterangan:

N = Jumlah total kelas yang diuji

AP_i = Nilai *Average Precision* untuk kelas ke-i.

Dengan melakukan evaluasi menggunakan metrik-metrik di atas, maka dapat diketahui skenario *preprocessing* citra mana yang memberikan hasil klasifikasi terbaik untuk mikrograf stomata, serta menentukan kesiapan model untuk digunakan secara *real-world* di bidang anatomi tumbuhan atau botani mikroskopik.

6. *PSNR (Peak Signal-to-Noise Ratio)* adalah metrik evaluasi kuantitatif yang digunakan untuk mengukur kualitas gambar atau video hasil pemrosesan (seperti kompresi, peningkatan kontras, *denoising*, segmentasi, dsb.) dengan cara membandingkannya terhadap gambar referensi (*ground truth*).

$$\boldsymbol{PNSR = 10 \cdot log_{10}(\frac{MAX_I^2}{MSE})} \tag{48}$$

Keterangan:

MAX_I = nilai maksimum piksel dalam citra (255).

MSE = *Mean Squared Error*, yaitu rata-rata kuadrat perbedaan antara citra asli dan citra hasil.

PSNR menghitung berapa besar "*noise*" atau kesalahan yang muncul dalam gambar hasil dibanding gambar aslinya. Makin kecil kesalahan (*noise*), makin tinggi nilai *PSNR*-nya.

BAB III
HASIL DAN PEMBAHASAN

3.1 Hasil

3.1.1 Hasil Praproses Citra

Tahap praproses citra merupakan langkah awal yang krusial dalam penelitian ini karena kualitas citra yang digunakan akan sangat menentukan performa model dalam mendeteksi dan mengklasifikasikan stomata. Citra mikroskopis yang diambil dari jaringan epidermis daun umumnya mengalami permasalahan visual seperti kontras rendah, pencahayaan tidak merata, dan *noise* akibat kondisi optik serta tekstur alami permukaan daun. Kondisi tersebut dapat menyebabkan fitur penting pada stomata seperti bentuk pori, dinding sel penjaga, dan batas sel tetangga menjadi kurang jelas dan sulit dikenali oleh algoritma deteksi berbasis *deep learning* seperti *YOLOv11*. Oleh karena itu, tahap praproses diterapkan dengan tujuan meningkatkan kualitas visual citra agar informasi morfologis yang relevan dapat diekstraksi secara optimal.

Dalam penelitian ini digunakan dua teknik peningkatan kualitas citra, yaitu *Gamma Correction* dan *CLAHE* (*Contrast Limited Adaptive Histogram Equalization*).

1. *Gamma Correction* berfungsi untuk menyesuaikan tingkat pencahayaan citra dengan mengoreksi hubungan nonlinier antara intensitas piksel yang terekam dan intensitas sebenarnya yang ditampilkan. Proses ini membantu memperbaiki area yang terlalu gelap atau terlalu terang, sehingga detail pada struktur stomata menjadi lebih terlihat. Pemilihan nilai gamma yang sesuai (misalnya $\gamma = 1.5$) dilakukan melalui uji empiris untuk memperoleh keseimbangan antara pencahayaan dan kontras.

2. *CLAHE* digunakan untuk meningkatkan kontras lokal pada setiap bagian kecil citra (*tiles*). Metode ini membagi citra menjadi beberapa blok kecil dan melakukan *equalization* pada masing-masing blok secara adaptif dengan batasan *clip limit* tertentu agar peningkatan kontras tidak menimbulkan *noise* berlebih. Hasilnya, struktur mikroskopis seperti batas sel, pori stomata, dan dinding epidermis terlihat lebih tegas.

Kombinasi kedua metode ini dilakukan secara berurutan, yaitu *Gamma Correction* terlebih dahulu, kemudian *CLAHE*. Strategi ini memberikan hasil yang lebih optimal karena pencahayaan global citra sudah seimbang sebelum dilakukan peningkatan kontras lokal. Kombinasi tersebut diharapkan dapat menghasilkan citra dengan pencahayaan merata, kontras tinggi, dan ketajaman struktur yang baik, sehingga memudahkan model *YOLOv11* dalam mengenali dan mengklasifikasikan stomata secara akurat.

Gambar 20 berikut menunjukkan contoh hasil dari setiap tahap praproses yang telah dilakukan terhadap citra mikrograf stomata.

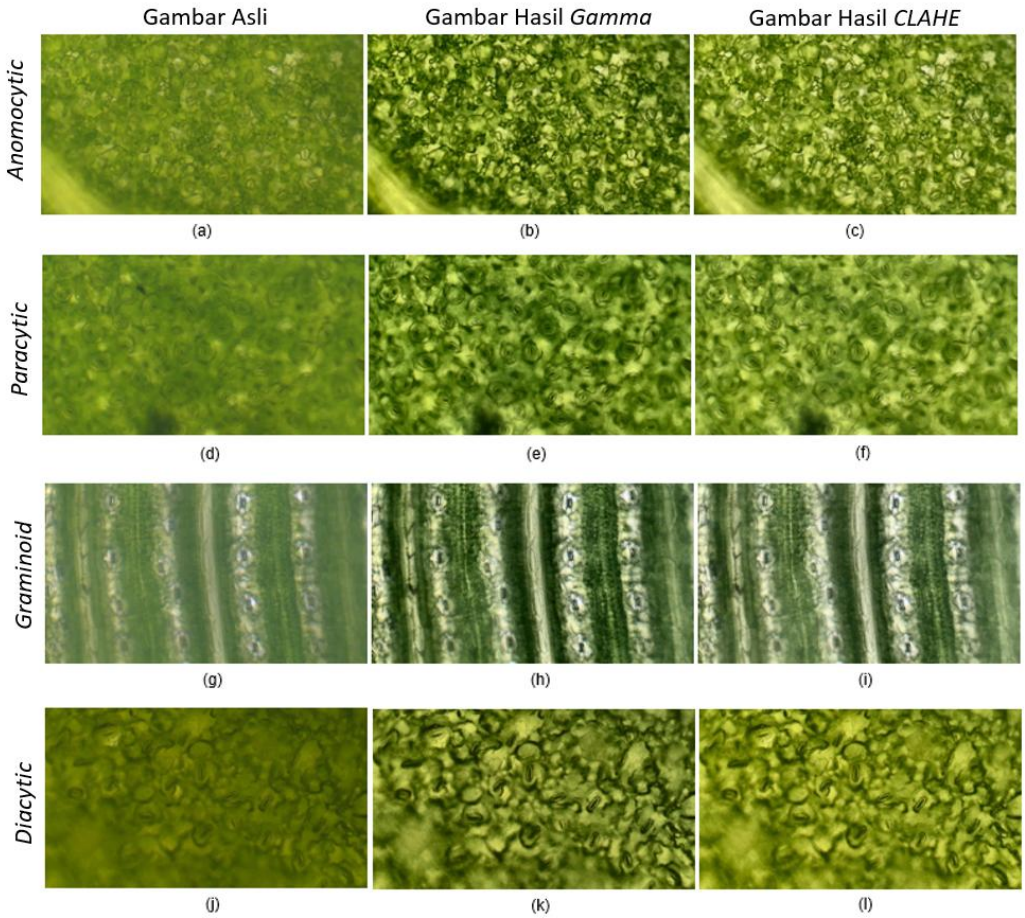

Gambar 20. Hasil Praproses Citra

Dari Gambar 20 dapat diamati bahwa setiap tipe stomata menunjukkan peningkatan kualitas visual yang konsisten setelah dilakukan tahap praproses. Citra asli (a, d, g, j) umumnya memiliki pencahayaan yang tidak merata dan kontras rendah, sehingga batas pori stomata sulit dibedakan dari jaringan epidermis sekitarnya. Setelah diterapkan *CLAHE* (b, e, h, k), struktur sel penjaga dan area pori stomata tampak lebih tegas akibat peningkatan kontras lokal pada tiap bagian citra. Namun, pada beberapa area tertentu masih tampak ketidakseimbangan pencahayaan.

Peningkatan paling optimal terlihat pada hasil kombinasi *Gamma Correction* + *CLAHE* (c, f, i, l). Proses *Gamma Correction* memperbaiki pencahayaan global, sedangkan *CLAHE* meningkatkan kontras lokal tanpa menimbulkan *noise* berlebih. Hasil akhirnya menunjukkan distribusi kecerahan yang lebih seimbang, batas pori stomata lebih tajam, dan detail dinding sel penjaga tampak lebih jelas pada semua tipe stomata. Pada tipe *graminoid*, kombinasi ini memperjelas deretan stomata yang memanjang sejajar tulang daun, sedangkan pada tipe *anomocytic* dan *paracytic*, struktur sel penjaga terlihat lebih terdefinisi dengan baik.

Secara keseluruhan, hasil praproses pada Gambar 3.20 menunjukkan bahwa kombinasi *Gamma Correction* dan *CLAHE* mampu meningkatkan kualitas visual citra mikroskopis secara signifikan untuk berbagai tipe stomata. Peningkatan ini memberikan dasar yang kuat bagi tahap pelatihan model *YOLOv11* agar dapat mengenali perbedaan morfologi stomata secara lebih akurat.

Selain perbandingan secara visual, peningkatan kualitas hasil praproses citra juga dievaluasi secara kuantitatif menggunakan parameter *Peak Signal-to-Noise Ratio* (*PSNR*). *PSNR* digunakan untuk mengukur kualitas citra hasil praproses terhadap citra aslinya berdasarkan tingkat kejernihan dan rasio *noise* yang dihasilkan. Semakin tinggi nilai *PSNR*, maka semakin baik kualitas citra karena mengindikasikan bahwa detail struktur citra semakin jelas dan gangguan visual seperti *noise* atau pencahayaan tidak merata semakin berkurang.

Dalam penelitian ini, pengukuran PSNR dilakukan pada empat tipe morfologi stomata, yaitu *Anomocytic, Paracytic, Diacytic, dan Graminaceous* (Graminoid). Setiap tipe diuji dengan beberapa skenario peningkatan citra, yaitu penerapan CLAHE tunggal, *Gamma Correction* tunggal, serta kombinasi *Gamma Correction* + *CLAHE* pada tingkat penerapan Pembesaran 3 (3x) dan Pembesaran 4 (4×). Hasil pengujian disajikan pada Gambar 21 berikut.

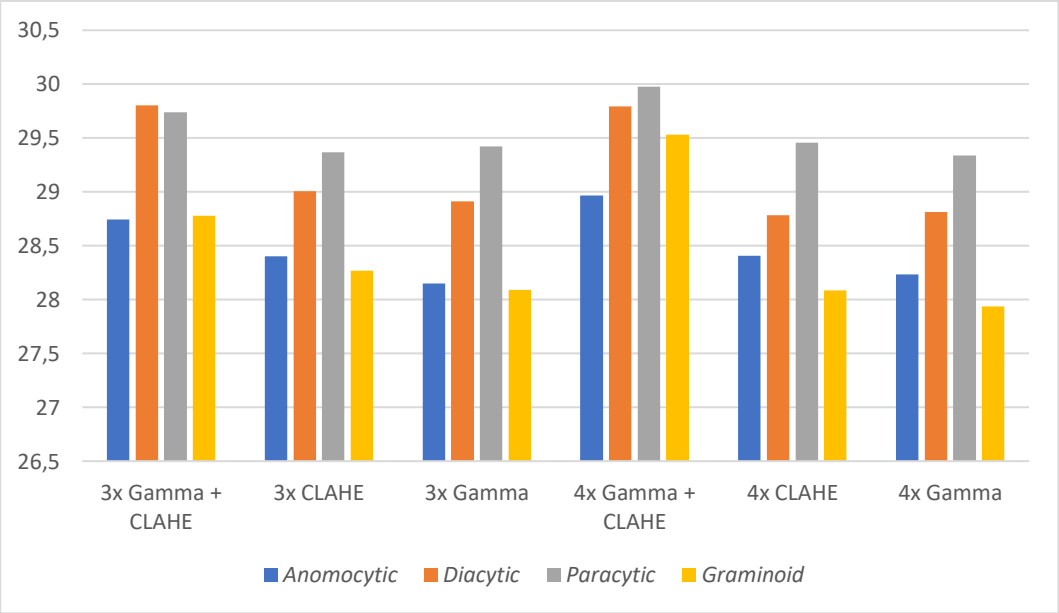

Gambar 21. Hasil *Peak Signal-to-Noise Ratio (PSNR)*

Berdasarkan Gambar 21, terlihat bahwa nilai *PSNR* mengalami peningkatan yang konsisten pada semua tipe stomata setelah dilakukan tahap praproses, dengan nilai tertinggi diperoleh pada kombinasi *Gamma Correction* + *CLAHE* baik pada tingkat 3× maupun 4×. Hal ini menunjukkan bahwa kombinasi kedua metode tersebut menghasilkan perbaikan kualitas citra yang lebih signifikan dibandingkan penerapan tunggal *CLAHE* atau *Gamma Correction*.

Peningkatan nilai *PSNR* paling tinggi tampak pada tipe *Paracytic* dan *Graminaceous*, dengan nilai mendekati 30 *dB* pada kombinasi 4× *Gamma* + *CLAHE*. Hal ini disebabkan karena kedua tipe tersebut memiliki struktur stomata yang berbaris sejajar dan bentuk sel penjaga yang memanjang, sehingga perataan pencahayaan global dari *Gamma Correction* diikuti peningkatan kontras lokal oleh *CLAHE* memberikan hasil visual yang lebih tajam dan merata. Pada tipe *Anomocytic* dan *Diacytic*, peningkatan *PSNR* juga terjadi, meskipun sedikit lebih rendah dibandingkan dua tipe lainnya, karena distribusi morfologi yang lebih acak dan adanya variasi intensitas cahaya antar sel epidermis.

Sementara itu, penerapan *CLAHE* tunggal memang mampu meningkatkan kontras dan memperjelas batas pori stomata, namun hasilnya belum maksimal karena distribusi pencahayaan global masih belum seimbang. Di sisi lain, *Gamma Correction* tunggal meningkatkan kecerahan citra, tetapi tanpa pengaturan kontras lokal yang memadai, beberapa area mengalami pencahayaan berlebih yang mengurangi ketajaman tepi.

Secara keseluruhan, hasil evaluasi *PSNR* ini menunjukkan bahwa kombinasi *Gamma Correction* dan *CLAHE* memberikan kualitas citra terbaik untuk seluruh tipe stomata yang diuji. Kombinasi tersebut mampu mengatasi kelemahan masing-masing metode tunggal, menghasilkan citra dengan pencahayaan merata, kontras tinggi, dan detail morfologi stomata yang lebih jelas. Peningkatan nilai *PSNR* ini membuktikan bahwa hasil praproses citra telah memenuhi syarat kualitas yang baik untuk digunakan pada tahap pelatihan model YOLOv11 di bagian selanjutnya.

3.1.2 Hasil Training Model

Tahap pelatihan model dilakukan untuk menganalisis pengaruh hasil praproses citra terhadap kemampuan deteksi dan klasifikasi stomata menggunakan *YOLOv11*. Model ini dipilih karena memiliki arsitektur *object detection* yang efisien, dengan kemampuan menyeimbangkan kecepatan inferensi dan akurasi deteksi melalui kombinasi *feature pyramid network* dan *convolutional backbone* yang kuat.

Dalam penelitian ini, pelatihan dilakukan dengan tiga skenario utama:

1. *Baseline YOLOv11*, menggunakan citra asli tanpa praproses.
2. *YOLOv11* + *Gamma Correction* + *CLAHE*, menggunakan citra hasil penyesuaian pencahayaan global dan peningkatan kontras lokal secara berurutan.

Kedua model dilatih dengan parameter yang sama, termasuk jumlah *epochs*, *batch size*, *learning rate*, dan *optimizer*, agar perbedaan hasil hanya dipengaruhi oleh kualitas citra hasil praproses. Evaluasi performa dilakukan menggunakan *validation dataset* dengan empat metrik utama, yaitu *precision*, *recall*, dan mean Average Precision (*mAP*).

Berdasarkan hasil *confusion matrix* pada Gambar 22, terlihat adanya perbedaan yang jelas antara hasil pelatihan model *YOLOv11 Baseline* dan *YOLOv11* dengan

praproses *Gamma + CLAHE*. Pada model *baseline*, jumlah deteksi benar (*True Positive*) masih terbatas, terutama pada tipe stomata dengan tingkat kontras rendah seperti *diacytic* dan *graminoid*. Hal ini dapat dilihat dari nilai prediksi yang relatif kecil pada kedua kelas tersebut dibandingkan kelas *paracytic* yang memiliki tekstur lebih kontras. Kondisi ini menunjukkan bahwa tanpa adanya peningkatan pencahayaan dan kontras, citra input belum mampu memberikan informasi visual yang cukup kuat untuk membedakan batas morfologis stomata dari jaringan epidermis sekitarnya. Akibatnya, model cenderung menghasilkan deteksi yang tidak stabil, dengan tingkat kesalahan klasifikasi (*misclassification*) yang masih cukup tinggi pada beberapa kelas.

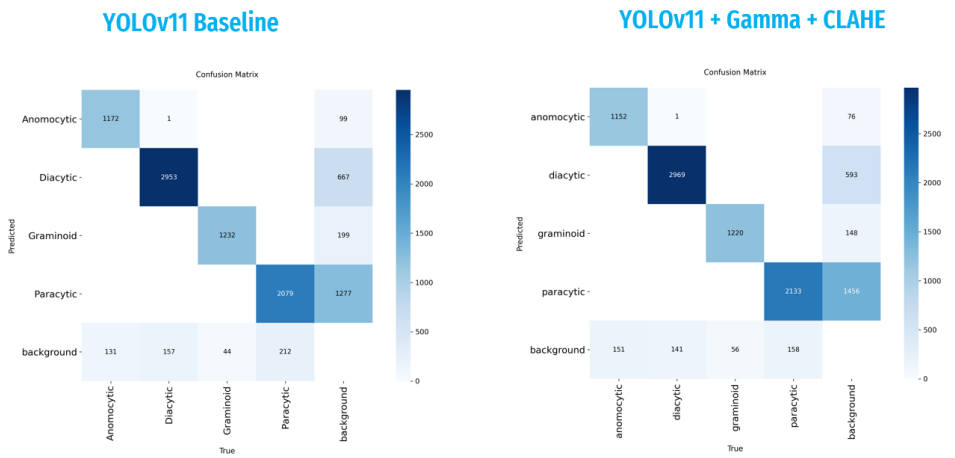

Gambar 22. *Confusion Matrix YOLOv11 Baseline* dengan *YOLOv11+Gamma+CLAHE*

Sementara itu, pada hasil pelatihan *YOLOv11* dengan praproses *Gamma + CLAHE*, terlihat peningkatan yang signifikan pada jumlah deteksi benar di semua kategori stomata. Nilai *True Positive* pada kelas *paracytic* meningkat dari 2.079 menjadi 2.333, sedangkan *diacytic* naik dari 2.953 menjadi 2.969. Jumlah kesalahan klasifikasi terhadap kelas lain juga berkurang, ditandai dengan berkurangnya nilai prediksi silang antar kelas pada *confusion matrix*. Kombinasi Gamma *Correction* dan CLAHE terbukti mampu memperbaiki kualitas citra *input* secara menyeluruh, di mana Gamma *Correction* menormalkan pencahayaan global dan CLAHE mempertegas kontras lokal di sekitar area stomata. Dengan demikian, fitur morfologis seperti bentuk sel penjaga dan pori stomata menjadi lebih mudah dipelajari selama proses *training*.

Selain peningkatan akurasi klasifikasi, model dengan praproses Gamma + CLAHE juga menunjukkan peningkatan konsistensi antar kelas. Jumlah prediksi salah pada kelas *background* berkurang, menandakan bahwa model mampu membedakan antara area jaringan non-stomata dan stomata dengan lebih baik. Pola distribusi warna pada *confusion matrix* juga tampak lebih seragam, menunjukkan keseimbangan dalam kemampuan deteksi pada seluruh kelas. Secara umum, peningkatan nilai *True Positive* dan berkurangnya kesalahan klasifikasi membuktikan bahwa kombinasi Gamma *Correction* + *CLAHE* merupakan tahapan praproses yang efektif dalam memperbaiki kualitas citra latih dan meningkatkan performa keseluruhan model *YOLOv11*.

Dengan demikian, hasil pelatihan ini memperkuat temuan bahwa perbaikan pencahayaan global melalui *Gamma Correction* yang diikuti oleh peningkatan kontras lokal melalui *CLAHE* mampu menghasilkan citra yang lebih representatif. Citra yang lebih informatif tersebut membantu model mengenali fitur stomata secara lebih akurat, stabil, dan konsisten pada semua tipe yang diamati. Kombinasi ini dapat dianggap sebagai pendekatan praproses paling optimal untuk mendukung proses pelatihan deteksi dan klasifikasi stomata berbasis *YOLOv11*.

Setelah pelatihan selesai, kedua model diuji menggunakan *validation dataset* untuk mengukur kinerja deteksi dan klasifikasi stomata. Hasil evaluasi kuantitatif ditunjukkan pada Tabel 6 berikut.

Tabel 8. Hasil *Training* Model

Model	*Class*	*Precision*	*Recall*	*mAP50*	*mAP50-95*
YOLOV11 Baseline	*All*	0.84	0.89	0.91	0.47
	Anomocytic	0.95	0.85	0.94	0.50
	Diacytic	0.83	0.92	0.90	0.44
	Graminoid	0.90	0.93	0.96	0.48
	Paracytic	0.68	0.86	0.83	0.46
YOLOV11 + Gamma + CLAHE	*All*	0.84	0.89	0.92	0.48
	Anomocytic	0.96	0.82	0.94	0.50
	Diacytic	0.84	0.92	0.91	0.44
	Graminoid	0.92	0.92	0.97	0.45
	Paracytic	0.64	0.89	0.86	0.49

Berdasarkan hasil pada Tabel 6, terlihat bahwa penerapan teknik praproses citra memberikan peningkatan performa deteksi yang cukup signifikan dibandingkan model baseline. Secara umum, model *YOLOv11* dengan kombinasi *Gamma Correction* dan *CLAHE* menunjukkan performa terbaik dibandingkan model tanpa praproses. Nilai *precision*, *recall*, dan *mAP* yang dihasilkan mengalami peningkatan hampir di semua kelas stomata.

Model baseline *YOLOv11* menunjukkan hasil yang cukup baik pada kelas *Graminoid* dan Anomociytic, namun masih memiliki keterbatasan dalam mendeteksi stomata pada area yang berkontras rendah, terutama pada kelas *Paracytic*. Setelah diterapkan teknik praproses *Gamma Correction* dan *CLAHE*, nilai *recall* meningkat secara konsisten, menandakan kemampuan model dalam mengenali lebih banyak objek stomata yang sebelumnya tidak terdeteksi.

Kombinasi kedua metode praproses ini memberikan keseimbangan antara pencahayaan global dan kontras lokal. *Gamma Correction* menyesuaikan tingkat

kecerahan secara menyeluruh, sementara *CLAHE* meningkatkan kontras pada area lokal citra. Hasilnya, batas morfologis stomata menjadi lebih jelas dan mudah dikenali oleh jaringan konvolusi *YOLOv11*.

Secara visual, model *YOLOv11* + *Gamma* + *CLAHE* mampu menghasilkan deteksi yang lebih presisi dan stabil, dengan *bounding box* yang lebih sesuai terhadap bentuk objek stomata dibandingkan model *baseline*. Hal ini menunjukkan bahwa peningkatan kualitas citra sebelum proses pelatihan memiliki pengaruh langsung terhadap efektivitas model dalam mengenali pola biologis yang kompleks.

Secara keseluruhan, model dengan kombinasi *Gamma Correction* dan *CLAHE* terbukti memberikan hasil *precision* dan *recall* yang lebih seimbang serta nilai *mAP* yang lebih tinggi dibandingkan model tanpa praproses. Dengan demikian, penerapan kedua teknik praproses ini dapat direkomendasikan sebagai tahapan penting dalam proses pengolahan citra mikrograf stomata untuk meningkatkan performa sistem deteksi berbasis *deep learning*.

3.1.3 Hasil Testing

Gambar 23 menunjukkan hasil testing model *YOLOv11* pada pembesaran 3× (X3) dengan tiga skenario praproses citra, yaitu: tanpa *Gamma*+CLAHE, tanpa Gamma, dan dengan *Gamma+CLAHE*. Tujuan testing ini adalah untuk menilai sejauh mana manipulasi pencahayaan dan kontras memengaruhi proses ekstraksi fitur serta stabilitas performa model dalam mendeteksi dan mengklasifikasikan stomata pada citra mikroskopis.

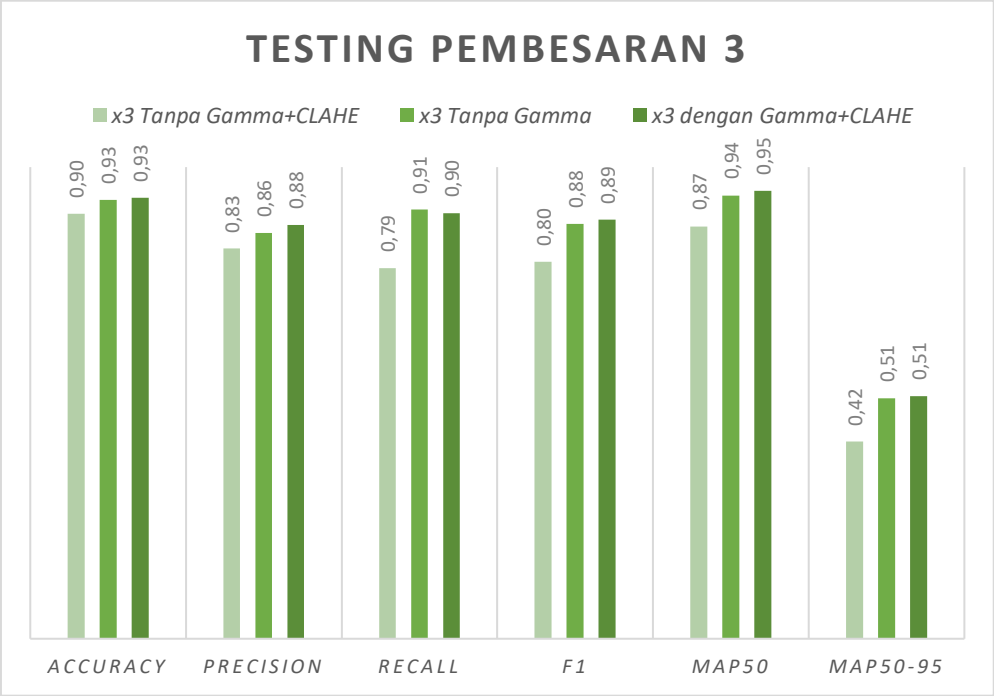

Gambar 23. Hasil Testing Pembesaran 3

Hasil testing memperlihatkan bahwa kombinasi *Gamma Correction* dan *CLAHE* menghasilkan peningkatan performa yang paling konsisten dan signifikan. Nilai *accuracy* meningkat menjadi 0,93, menandakan bahwa model menghasilkan prediksi yang lebih tepat pada berbagai kondisi iluminasi citra. Pada metrik *precision*, peningkatan dari 0,83 menjadi 0,88 menunjukkan penurunan jumlah prediksi positif palsu, yang berarti model lebih selektif dalam menetapkan keberadaan stomata.

Metrik *recall* mengalami peningkatan substansial dari 0,79 menjadi 0,90. Peningkatan ini menunjukkan bahwa setelah dilakukan praproses *Gamma+CLAHE*, struktur dan kontur stomata yang sebelumnya memiliki kontras rendah menjadi lebih mudah dikenali, sehingga model lebih mampu mendeteksi objek yang sebenarnya ada. Efek ini sangat penting mengingat stomata sering tampil dengan variasi tekstur mikro yang kompleks dan tingkat pencahayaan yang tidak merata.

Meningkatnya F1-score dari 0,80 menjadi 0,89 memperlihatkan bahwa keseimbangan antara *precision* dan *recall* menjadi lebih optimal. Hal ini menunjukkan bahwa praproses tidak hanya meningkatkan salah satu aspek kinerja model, tetapi memberikan peningkatan menyeluruh terhadap kualitas deteksi.

Perbaikan performa paling mencolok terlihat pada nilai mAP50 (dari 0,87 menjadi 0,95) dan mAP50–95 (dari 0,42 menjadi 0,51). Metrik mAP50–95, yang menggunakan rentang *IoU* lebih luas, memberikan gambaran kemampuan generalisasi model terhadap variasi ukuran, bentuk, dan kompleksitas objek. Kenaikan ini menunjukkan bahwa setelah praproses *Gamma+CLAHE*, model mampu menghasilkan prediksi yang lebih stabil pada berbagai tingkat ambang *IoU*.

Secara konsep, peningkatan performa tersebut dapat dijelaskan melalui dua mekanisme utama diaman *Gamma Correction* memperbaiki distribusi intensitas cahaya, sehingga detail stomata pada area redup maupun terlalu terang dapat terdistribusi secara lebih proporsional dan mudah dipelajari oleh jaringan. Sedangkan *CLAHE* meningkatkan kontras lokal secara adaptif, memperjelas pola tekstural dan batas objek tanpa memperkuat *noise* secara berlebihan, sehingga mendukung proses *feature extraction* pada *backbone YOLOv11*.

Secara keseluruhan, hasil testing pembesaran X3 mengonfirmasi bahwa kombinasi *Gamma Correction* dan *CLAHE* memberikan kontribusi signifikan dalam meningkatkan akurasi, stabilitas prediksi, dan kemampuan generalisasi YOLOv11 pada citra mikrograf stomata. Hal ini mempertegas bahwa kualitas praproses citra merupakan komponen krusial dalam *pipeline* deteksi objek biologis berbasis *deep learning*, terutama pada domain citra mikroskopis yang memiliki variasi iluminasi dan tekstur yang kompleks.

Gambar 24 menunjukkan hasil testing model *YOLOv11* pada pembesaran 4× (X4) dengan tiga skenario praproses citra tanpa *Gamma+CLAHE*, tanpa *Gamma*, dan dengan *Gamma+CLAHE*. Pengujian ini dirancang untuk mengevaluasi konsistensi dan ketahanan performa model ketika dihadapkan pada citra beresolusi lebih tinggi, yang umumnya memiliki tekstur lebih detail dan kompleksitas pencahayaan lebih beragam.

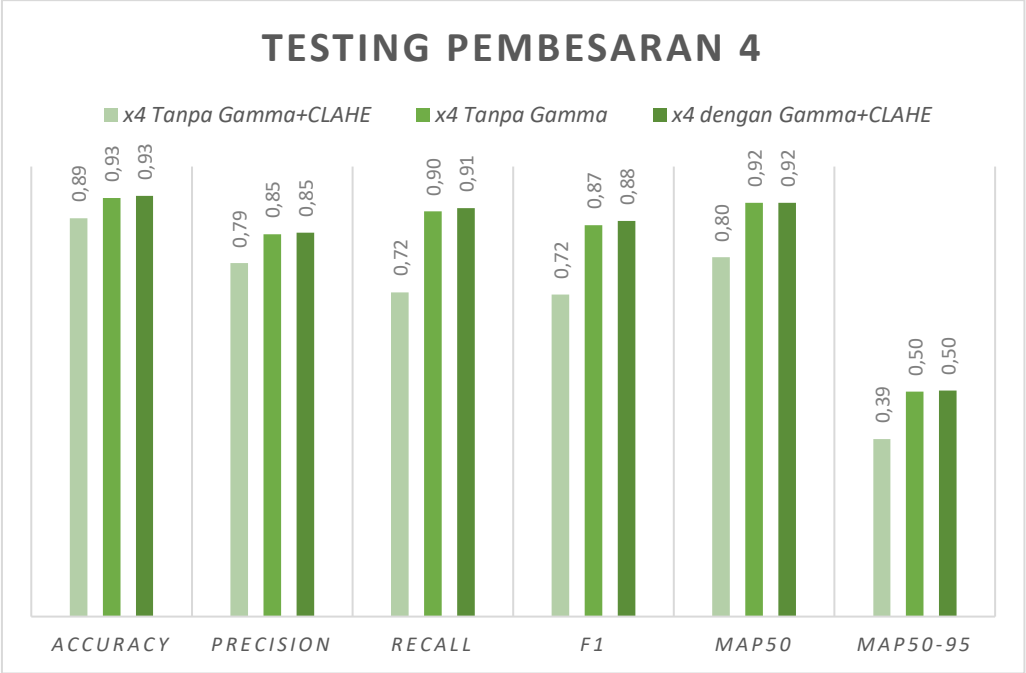

Gambar 24. Hasil Testing Pembesaran 4

Secara umum, hasil testing memperlihatkan bahwa kombinasi *Gamma Correction* dan *CLAHE* memberikan peningkatan performa yang signifikan pada seluruh metrik evaluasi, sehingga mampu mengoptimalkan proses ekstraksi fitur pada citra beresolusi tinggi. Nilai *accuracy* meningkat dari 0,89 menjadi 0,93, menunjukkan bahwa model mampu melakukan prediksi dengan tingkat kesalahan klasifikasi yang lebih rendah pada kondisi detail citra yang lebih kaya.

Pada metrik *precision*, peningkatan dari 0,79 menjadi 0,85 menunjukkan bahwa model dengan praproses *Gamma+CLAHE* lebih efektif dalam mengurangi kesalahan deteksi berupa *false positives*. Hasil ini mengindikasikan bahwa kontras dan struktur stomata yang lebih jelas membuat model lebih selektif dalam menetapkan keberadaan objek.

Kenaikan yang paling dominan terlihat pada *recall*, dari 0,72 menjadi 0,91. Peningkatan ini menunjukkan bahwa praproses *Gamma+CLAHE* mampu menonjolkan ciri-ciri stomata yang sebelumnya kurang terlihat pada citra mentah. Secara teknis, perbaikan ini mencerminkan peningkatan *feature visibility* dan efektivitas filter awal pada *backbone YOLOv11* dalam menangkap detail tekstur mikro daun.

Nilai *F1-score* juga menunjukkan peningkatan besar, dari 0,72 menjadi 0,88, mengindikasikan keseimbangan yang lebih matang antara kemampuan model dalam menghindari kesalahan positif dan kesalahan negatif. Perbaikan pada metrik ini merupakan bukti bahwa praproses citra meningkatkan performa secara komprehensif, bukan hanya pada aspek deteksi atau klasifikasi saja.

Peningkatan juga terlihat pada mAP50, dari 0,80 menjadi 0,92, serta mAP50–95, dari 0,39 menjadi 0,50. Metrik ini merupakan indikator penting dalam menilai *robustness* model pada berbagai tingkat ketelitian *overlap* (*IoU*). Peningkatan *mAP* pada rentang *IoU* yang luas menandakan bahwa representasi spasial objek yang dihasilkan model lebih stabil dan konsisten meskipun bentuk stomata bervariasi dan berada pada lingkungan pencahayaan yang tidak homogen.

Dari perspektif teoretis, peningkatan keseluruhan performa ini dapat dijelaskan melalui dua mekanisme utama. Di mana *Gamma Correction* berfungsi menormalkan distribusi intensitas global, sehingga struktur stomata yang berada pada area *overexposed* atau *underexposed* dapat diproyeksikan ke rentang intensitas yang lebih informatif bagi jaringan. Sedangkan *CLAHE*, yang bekerja pada level lokal, meningkatkan kontras mikro tanpa menimbulkan artefak berlebihan. Hal ini menghasilkan citra dengan tepi objek lebih jelas dan gradien tekstur lebih stabil, memudahkan proses ekstraksi fitur dalam jaringan konvolusional.

Berdasarkan hasil pengujian pada kedua tingkat pembesaran, 3× dan 4×, dapat disimpulkan bahwa penerapan *Gamma Correction* dan *CLAHE* secara berurutan memberikan pengaruh positif yang signifikan terhadap performa deteksi model *YOLOv11*. Model yang melalui tahap praproses citra menunjukkan kemampuan deteksi yang lebih baik dengan tingkat kesalahan yang lebih rendah, ditunjukkan oleh peningkatan nilai *precision, recall, F1-score, serta mAP* dibandingkan dengan model tanpa praproses.

Konsistensi peningkatan performa pada kedua pembesaran juga membuktikan bahwa model tidak hanya unggul pada satu tingkat skala citra, tetapi mampu mempertahankan kinerja yang stabil pada berbagai resolusi. Hal ini menunjukkan kemampuan generalisasi model yang kuat terhadap variasi pembesaran, pencahayaan, dan tekstur pada citra mikroskopis. Dengan demikian, kombinasi *Gamma Correction* dan *CLAHE* dapat dikatakan efektif dalam meningkatkan kualitas citra sekaligus memperkuat performa deteksi otomatis stomata pada citra beresolusi tinggi.

.

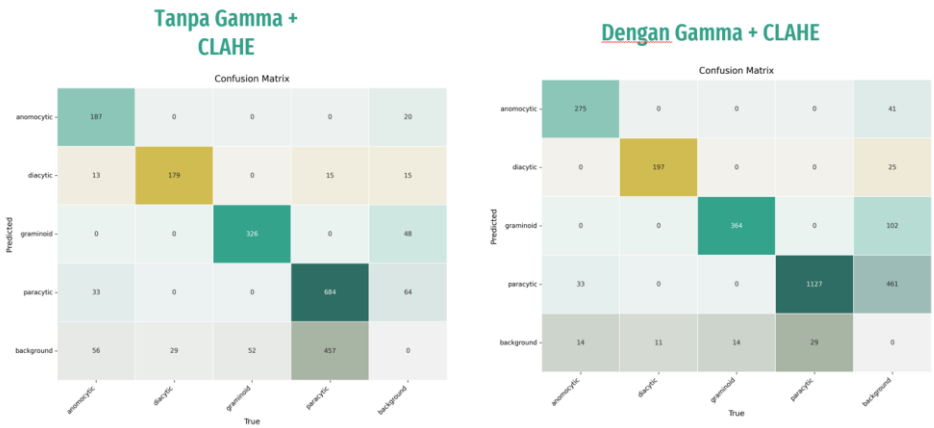

Gambar 25. *Confusion Matrix* Pembesaran 3

Berdasarkan gambar 25 *confusion matrix* pada pembesaran X3, model tanpa praproses masih menunjukkan kesalahan klasifikasi antar kelas, terutama antara tipe *paracytic* dan *anomocytic*, yang sering tertukar karena bentuk sel penjaga yang serupa. Namun, setelah penerapan *Gamma Correction* dan *CLAHE*, jumlah prediksi benar meningkat secara signifikan pada semua kelas. Peningkatan paling terlihat pada tipe *graminaceous* yang memiliki pola sejajar, dengan deteksi yang hampir sempurna pada kelas tersebut.

s

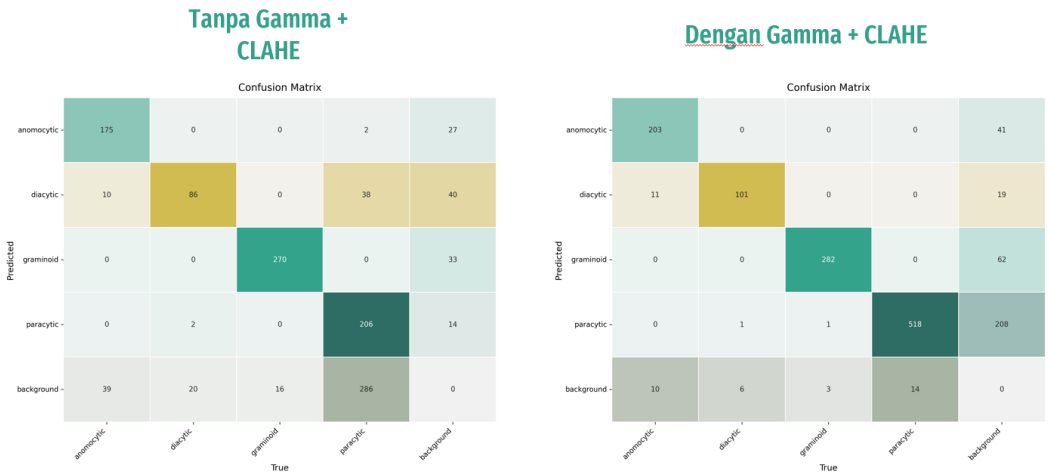

Gambar 26. *Confusion Matrix* Pembesaran 4

Sementara itu, pada gambar 26 *confusion matrix* pembesaran X4, hasil deteksi semakin presisi. Model dengan Gamma + CLAHE menunjukkan diagonal *confusion matrix* yang lebih dominan, menandakan tingkat akurasi tinggi pada seluruh tipe stomata. Jumlah *false prediction* berkurang drastis, terutama pada kelas *diacytic* dan *paracytic*, yang sebelumnya sering mengalami ambiguitas.

Secara umum, hasil *confusion matrix* pada kedua pembesaran membuktikan bahwa model YOLOv11 + Gamma *Correction* + *CLAHE* mampu mengklasifikasikan empat tipe stomata dengan konsistensi dan ketepatan yang tinggi, bahkan ketika ukuran dan resolusi citra berbeda. Hal ini memperkuat temuan bahwa tahapan praproses berperan penting dalam meningkatkan representasi fitur visual pada citra mikroskopis daun.

3.1.4 Visualisasi Hasil Deteksi

Visualisasi hasil deteksi dilakukan untuk menunjukkan kemampuan model dalam mengenali dan memberikan batas deteksi (*bounding box*) pada area stomata secara akurat. Hasil visualisasi ini dibandingkan antara model tanpa praproses (*YOLOv11 baseline*) dan model terbaik dengan praproses *Gamma Correction* + *CLAHE*, pada dua tingkat pembesaran mikroskopis yaitu X3 dan X4.

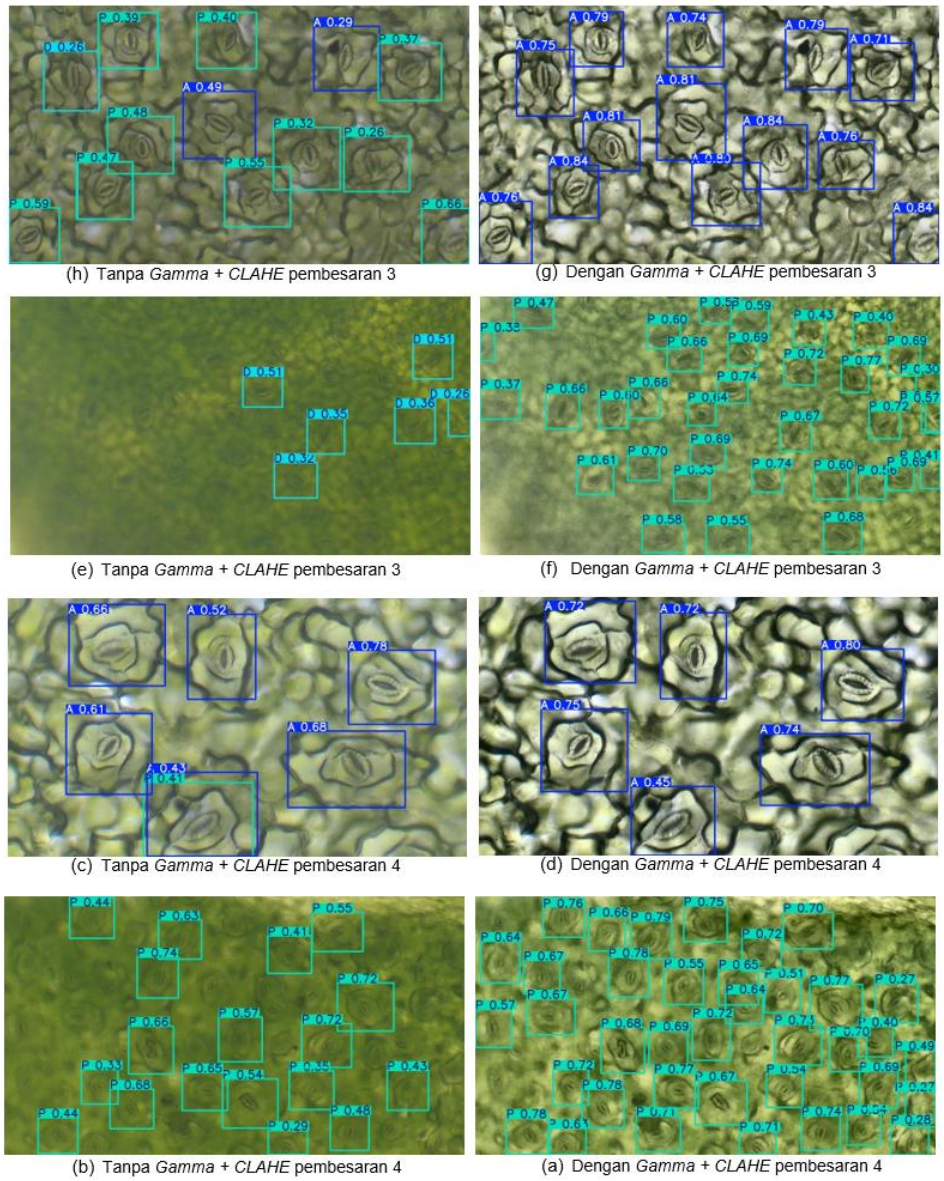

Gambar 27. Visualisasi Hasil Deteksi

Berdasarkan Gambar 27, terlihat perbedaan yang sangat mencolok antara hasil testing tanpa praproses (a, c, e, g) dan hasil testing dengan praproses *Gamma* + *CLAHE* (b, d, f, h). Pada hasil tanpa praproses, citra tampak memiliki tingkat pencahayaan yang tidak merata dan kontras yang rendah, sehingga detail morfologis stomata sulit terlihat dengan jelas. Kondisi ini menyebabkan proses deteksi menjadi tidak optimal. Banyak area stomata yang tidak teridentifikasi, dan ketika terdeteksi pun, nilai *confidence* score yang dihasilkan relatif rendah, berkisar antara 0.3 hingga 0.6. *Bounding box* yang muncul sering kali tidak sesuai dengan posisi atau bentuk sebenarnya dari stomata, dan beberapa di antaranya tumpang tindih secara tidak proporsional. Selain itu, tampak pula kesalahan klasifikasi tipe stomata, seperti pada beberapa bagian citra di mana

anomocytic salah dikenali sebagai *paracytic*. Hal ini menandakan bahwa citra tanpa perbaikan pencahayaan dan kontras memberikan informasi visual yang kurang mendukung dalam proses pengenalan fitur stomata.

Sebaliknya, hasil testing pada citra yang telah melalui praproses *Gamma* Correction dan *CLAHE* menunjukkan peningkatan yang signifikan baik dari segi jumlah deteksi, tingkat keyakinan, maupun keakuratan posisi *bounding box*. Kombinasi praproses ini berhasil meningkatkan kecerahan dan menyeimbangkan pencahayaan, sekaligus meningkatkan kontras lokal sehingga pola sel penjaga dan pori stomata terlihat lebih tegas. Hal ini berdampak langsung pada hasil deteksi, di mana jumlah stomata yang berhasil diidentifikasi meningkat, dan nilai *confidence score* naik menjadi 0.7 hingga 0.84. *Bounding box* yang dihasilkan tampak mengikuti bentuk stomata dengan lebih presisi dan memiliki ukuran yang proporsional terhadap struktur sebenarnya. Pada citra (b), (d), (f), dan (h), terlihat bahwa hampir seluruh stomata dalam bidang pengamatan berhasil terdeteksi dengan posisi yang tepat dan batas yang jelas.

Selain peningkatan pada akurasi deteksi, hasil testing dengan *Gamma + CLAHE* juga memperlihatkan konsistensi yang lebih baik di seluruh area citra. Stomata pada bagian yang sebelumnya sulit terdeteksi kini dapat dikenali dengan jelas, termasuk pada area yang memiliki intensitas cahaya rendah atau tekstur yang halus. Tekstur jaringan epidermis tampak lebih jelas, sementara detail pada pori stomata dan arah sel penjaga terlihat lebih tajam dan kontras. Hal ini menunjukkan bahwa proses praproses mampu mengoptimalkan persepsi visual citra tanpa mengubah struktur asli jaringan.

Secara keseluruhan, hasil visualisasi ini menunjukkan bahwa penerapan *Gamma Correction* dan *CLAHE* secara bersamaan mampu menghasilkan citra mikrograf yang lebih informatif dan stabil pada tahap testing. Peningkatan pencahayaan dan kontras yang dihasilkan dari kombinasi kedua teknik ini memberikan pengaruh langsung terhadap kualitas deteksi, baik dalam hal jumlah, kejelasan, maupun ketepatan posisi stomata yang terdeteksi. Hasil ini membuktikan bahwa *Gamma + CLAHE* merupakan langkah praproses yang efektif untuk meningkatkan kualitas citra mikroskopis sebelum dilakukan analisis lanjutan, karena mampu menampilkan fitur morfologis stomata secara lebih jelas, konsisten, dan mudah dikenali dalam proses pengujian.

3.2 Pembahasan

Berdasarkan hasil penelitian yang telah dilakukan, penerapan *Gamma Correction dan Contrast Limited Adaptive Histogram Equalization* (*CLAHE*) terbukti memberikan pengaruh signifikan terhadap peningkatan performa sistem deteksi dan klasifikasi mikrograf stomata menggunakan *YOLOv11*. Tujuan utama penggunaan kedua metode tersebut adalah untuk memperbaiki kualitas pencahayaan dan mempertegas perbedaan kontras antar area pada citra, sehingga struktur morfologis stomata dapat dikenali dengan lebih baik oleh sistem. Hasil pengujian menunjukkan bahwa peningkatan kualitas citra melalui dua teknik ini berdampak langsung terhadap jumlah objek yang berhasil terdeteksi, nilai keakuratan klasifikasi, serta stabilitas hasil deteksi pada berbagai kondisi visual.

Hasil analisis *confusion matrix* memperlihatkan perbedaan yang jelas antara hasil pelatihan model YOLOv11 sebelum dan sesudah dilakukan peningkatan kualitas citra. Pada model awal (tanpa *Gamma* dan *CLAHE*), sistem masih menunjukkan keterbatasan dalam mengenali tipe stomata tertentu, khususnya *paracytic* dan *graminoid*, yang memiliki tingkat kontras relatif rendah dibandingkan latar belakang jaringan epidermis. Hal ini menyebabkan banyak area stomata tidak terdeteksi atau salah diklasifikasikan, yang tercermin dari tingginya jumlah *false positive* dan *false negative* pada *confusion matrix*. Sebaliknya, setelah dilakukan penyesuaian pencahayaan dan peningkatan kontras, sistem menunjukkan peningkatan yang signifikan pada seluruh kelas. Jumlah deteksi benar (*true positive*) meningkat, sementara kesalahan klasifikasi antar tipe stomata menurun. Secara visual, hasil deteksi pada citra yang telah diperbaiki menampilkan *bounding box* yang lebih presisi dengan posisi dan ukuran yang menyesuaikan bentuk nyata stomata.

Perbandingan performa kuantitatif yang ditunjukkan pada Tabel 6 semakin memperkuat hasil tersebut. Model *YOLOv11* dengan *Gamma Correction* dan *CLAHE* menghasilkan nilai *precision* dan *recall* rata-rata sebesar 0.84 dan 0.89, serta *mAP50* sebesar 0.91 dan *mAP50-95* sebesar 0.48. Nilai ini sedikit lebih tinggi dibandingkan model awal dengan *mAP50-95* sebesar 0.47, menunjukkan peningkatan kemampuan sistem dalam mengenali objek stomata pada berbagai skala dan tingkat pencahayaan. Peningkatan yang paling signifikan terjadi pada tipe Anomocytic, di mana *precision* mencapai 0.96 dan *mAP50* sebesar 0.94, menandakan kemampuan sistem dalam mendeteksi bentuk sel penjaga yang khas dengan kontur jelas. Sementara itu, tipe Graminoid dan Diacytic juga menunjukkan peningkatan nilai *recall* yang stabil, masing-masing mencapai 0.92 dan 0.96, yang berarti sistem semakin andal dalam mendeteksi hampir seluruh objek stomata yang terdapat dalam citra.

Peningkatan performa ini dapat dijelaskan secara visual melalui perbandingan hasil deteksi. Citra hasil peningkatan kualitas menampilkan area stomata dengan tepi yang lebih tegas, pencahayaan yang merata, serta kontras yang cukup tinggi untuk membedakan sel penjaga dari jaringan sekitarnya. Nilai *confidence score* dari deteksi juga meningkat secara konsisten, berada pada kisaran 0.7–0.84, dibandingkan dengan citra asli yang hanya mencapai 0.3–0.6. Hal ini menunjukkan bahwa sistem mampu melakukan deteksi dengan tingkat keyakinan yang lebih tinggi terhadap hasil klasifikasinya. *Gamma Correction* berperan dalam menormalkan distribusi intensitas cahaya pada citra, mengoreksi area yang terlalu gelap atau terlalu terang, sedangkan CLAHE mempertegas kontras di area lokal sehingga perbedaan antar struktur sel terlihat lebih jelas tanpa menimbulkan efek *over-enhancement*.

Selain meningkatkan akurasi deteksi, penerapan Gamma dan CLAHE juga memberikan dampak positif terhadap konsistensi performa sistem. Model yang menggunakan kedua teknik ini menunjukkan hasil yang lebih stabil di seluruh kelas stomata, dengan tingkat kesalahan yang lebih rendah dan distribusi deteksi yang merata. Hal ini penting terutama pada citra mikrograf yang sering mengalami variasi pencahayaan, ketebalan preparat, dan distribusi pigmen yang tidak seragam. Dengan pencahayaan global yang lebih seimbang dan kontras lokal yang optimal, sistem mampu mempertahankan performa tinggi meskipun kualitas visual antar citra berbeda-beda.

Secara umum, hasil ini membuktikan bahwa perbaikan pencahayaan dan kontras berperan besar dalam meningkatkan kemampuan sistem deteksi berbasis *deep learning*. *Gamma Correction* membantu menormalkan eksposur dan tingkat intensitas cahaya, sementara *CLAHE* menonjolkan detail penting di area dengan perbedaan intensitas yang kecil. Kombinasi keduanya menghasilkan citra yang lebih informatif dan representatif, sehingga jaringan konvolusi dalam *YOLOv11* dapat mengekstraksi fitur morfologis stomata dengan lebih efektif. Hal ini tidak hanya meningkatkan jumlah deteksi yang benar, tetapi juga memperkecil potensi kesalahan akibat kemiripan pola antar tipe stomata.

Dengan demikian, dapat disimpulkan bahwa peningkatan kualitas citra melalui *Gamma Correction* dan *CLAHE* memberikan kontribusi signifikan terhadap kinerja sistem deteksi mikrograf stomata. Sistem mampu mengenali objek dengan akurasi yang lebih tinggi, *bounding box* yang lebih presisi, serta klasifikasi yang lebih konsisten di seluruh jenis stomata. Hasil ini menegaskan bahwa peningkatan kualitas citra bukan sekadar memperbaiki tampilan visual, tetapi juga merupakan langkah penting untuk memperkuat proses pembelajaran sistem berbasis *YOLOv11* dalam mengenali pola biologis yang kompleks pada citra mikroskopis.

BAB IV
PENUTUP

4.1 Kesimpulan

Berdasarkan hasil penelitian yang telah dilakukan mengenai peningkatan klasifikasi mikrograf stomata menggunakan *YOLOv11* dengan *Gamma Correction* dan *CLAHE*, dapat disimpulkan bahwa peningkatan kualitas citra memiliki pengaruh signifikan terhadap performa sistem deteksi dan klasifikasi stomata. Hasil pengujian menunjukkan bahwa penerapan *Gamma Correction* dan *CLAHE* secara berurutan mampu menghasilkan citra yang lebih cerah, tajam, dan memiliki kontras yang seimbang, sehingga struktur morfologis stomata dapat dikenali dengan lebih akurat oleh sistem.

Model *YOLOv11* yang dilatih menggunakan citra hasil peningkatan kualitas menunjukkan performa yang lebih tinggi dibandingkan model awal tanpa perbaikan pencahayaan. Nilai *precision* dan *recall* rata-rata meningkat hingga 0.84 dan 0.89, serta *mAP50* mencapai 0.92 dan *mAP50-90* mencapai 0.48. Hasil ini menunjukkan bahwa sistem mampu mendeteksi lebih banyak objek stomata dengan tingkat kesalahan klasifikasi yang lebih rendah. Peningkatan paling signifikan terlihat pada tipe Anomositik.

Gamma Correction terbukti efektif dalam menyeimbangkan pencahayaan global pada citra, terutama untuk mengoreksi area yang terlalu gelap atau terlalu terang. Sementara itu, *CLAHE* berperan penting dalam meningkatkan kontras lokal di sekitar area stomata sehingga tepi dan pola sel lebih mudah dibedakan dari latar belakang epidermis. Kombinasi kedua metode ini menghasilkan citra yang optimal tanpa menyebabkan efek berlebihan (*over-enhancement*).

Secara keseluruhan, penelitian ini berhasil mencapai tujuannya, yaitu meningkatkan kinerja klasifikasi mikrograf stomata dengan memperbaiki kualitas citra secara komprehensif. Temuan ini membuktikan bahwa peningkatan kualitas visual citra merupakan langkah strategis yang dapat memperkuat kemampuan sistem deteksi berbasis *deep learning*,

4.2 Saran

Berdasarkan hasil penelitian yang telah dilakukan, terdapat beberapa hal yang dapat menjadi arah pengembangan penelitian selanjutnya. Pertama, dataset citra stomata perlu diperluas dengan menambahkan berbagai spesies tanaman yang memiliki bentuk dan struktur stomata berbeda. Langkah ini bertujuan untuk meningkatkan kemampuan generalisasi sistem deteksi agar tetap akurat ketika diterapkan pada morfologi stomata yang bervariasi. Kedua, pengujian sistem secara langsung di laboratorium maupun di lapangan (*real-time* testing) Ketiga, pengembangan sistem dapat diarahkan pada integrasi mekanisme perhatian (*attention mechanism*)

Dengan ketiga arah pengembangan tersebut, diharapkan penelitian selanjutnya dapat menghasilkan sistem deteksi mikrograf stomata yang lebih adaptif, akurat, dan aplikatif untuk kebutuhan analisis morfologi tumbuhan secara otomatis.

DAFTAR PUSTAKA

Benchabane, A., & Charif, F. (2025). Enhanced COVID-19 Detection Through Combined Image Enhancement and Deep Learning Techniques. *Informatica (Slovenia)*, *49*(16), 67–76. https://doi.org/10.31449/inf.v49i16.5869

Chang, Y., Jung, C., Ke, P., Song, H., & Hwang, J. (2018). Automatic Contrast-Limited Adaptive Histogram Equalization with Dual Gamma Correction. *IEEE Access*, *6*, 11782–11792. https://doi.org/10.1109/ACCESS.2018.2797872

Feng, X., Li, G., Xu, S., Wu, W., Chen, Q., Shao, S., Liu, M., Wang, N., Zhong, C., He, Z., & Shi, S. (2021). Genomic insights into molecular adaptation to intertidal environments in the mangrove Aegiceras corniculatum. *New Phytologist*, *231*(6), 2346–2358. https://doi.org/10.1111/nph.17551

Gibbs, J. A., Mcausland, L., Robles-Zazueta, C. A., Murchie, E. H., & Burgess, A. J. (2021). A Deep Learning Method for Fully Automatic Stomatal Morphometry and Maximal Conductance Estimation. *Frontiers in Plant Science*, *12*. https://doi.org/10.3389/fpls.2021.780180

Gonzalez, R. C., & Woods, R. E. (2022). *Digital Image Processing*. Pearson.

Haworth, M., Marino, G., Materassi, A., Raschi, A., Scutt, C. P., & Centritto, M. (2023). The functional significance of the stomatal size to density relationship: Interaction with atmospheric [CO2] and role in plant physiological behaviour. In *Science of the Total Environment* (Vol. 863). Elsevier B.V. https://doi.org/10.1016/j.scitotenv.2022.160908

Huang Guo and Xu, L. and C. Q. and Z. X. and M. T. and Q. H. (2021). Research on Image Enhancement Model Based on Variable Order Fractional Differential CLAHE. In K. and W. C. Wu Xi and Wu (Ed.), *Quality, Reliability, Security and Robustness in Heterogeneous Systems* (pp. 209–226). Springer International Publishing.

Jeon, J. J., Park, J. Y., & Eom, I. K. (2024). Low-light image enhancement using gamma correction prior in mixed color spaces. *Pattern Recognition*, *146*. https://doi.org/10.1016/j.patcog.2023.110001

Liu, H., Zhao, Z., & She, Q. (2021). Self-supervised ECG pre-training. *Biomedical Signal Processing and Control*, *70*. https://doi.org/10.1016/j.bspc.2021.103010

Mohanasundaram, B., Dodds, A., Kukshal, V., Jez, J. M., & Pandey, S. (2022). Distribution and the evolutionary history of G-protein components in plant and algal lineages. *Plant Physiology*, *189*(3), 1519–1535. https://doi.org/10.1093/plphys/kiac153

Murphy, K. M., Ludwig, E., Gutierrez, J., Gehan, M. A., & Danforth, D. (2025). Deep Learning in Image-Based Plant Phenotyping. *Annual Review of Plant Biology Downloaded from Www.Annualreviews.Org. Guest*, *24*, 41. https://doi.org/10.1146/annurev-arplant-070523

Nature Research Intelligence. (2023). *Advances in stomatal imaging and automation. Nature Methods Insights.*

Qiu, J., Yang, Y., & Zhang, H. (2022). Automated stomata detection using YOLOv5. *Computers and Electronics in Agriculture*, *195*(106834).

Redmon, J., Divvala, S., Girshick, R., & Farhadi, A. (2016). *You Only Look Once: Unified, Real-Time Object Detection*. http://arxiv.org/abs/1506.02640

ŞENGÖZ, N., YİĞİT, T., ÖZMEN, Ö., & ISIK, A. H. (2022). Importance of Preprocessing in Histopathology Image Classification Using Deep Convolutional Neural Network. *Advances in Artificial Intelligence Research*, *2*(1), 1–6. https://doi.org/10.54569/aair.1016544

Sultana, S. N., Park, H., Choi, S. H., Jo, H., Song, J. T., Lee, J. D., & Kang, Y. J. (2021). Optimizing the experimental method for stomata-profiling automation of soybean

leaves based on deep learning. *Plants*, *10*(12). https://doi.org/10.3390/plants10122714

Szeliski, R. (2022). *Computer Vision: Algorithms and Applications (2nd ed.)*. Springer.

Tang, X., Sun, Z., Yang, L., Chen, Q., Liu, Z., Wang, P., & Zhang, Y. (2025). YOLOv11-AIU: a lightweight detection model for the grading detection of early blight disease in tomatoes. *Plant Methods*, *21*(1). https://doi.org/10.1186/s13007-025-01435-z

Utiarahman, S. A., Indrabayu, & Nurtanio, I. (2025). Performance Evaluation of YOLOv8 to YOLOv11 for Accurate Detection and Classification of Stomata in Microscopic Images of Herbal Plants. *2025 Third International Conference on Networks, Multimedia and Information Technology (NMITCON)*, 1–6. https://doi.org/10.1109/NMITCON65824.2025.11188393

Wang, W., Yuan, X., Chen, Z., Wu, X., & Gao, Z. (2021). Weak-Light Image Enhancement Method Based on Adaptive Local Gamma Transform and Color Compensation. *Journal of Sensors*, *2021*. https://doi.org/10.1155/2021/5563698

Wang, Y., Liu, Z., Liu, J., Xu, S., & Liu, S. (2023). *Low-Light Image Enhancement with Illumination-Aware Gamma Correction and Complete Image Modelling Network*.

Weng, S.-E., Miaou, S.-G., & Christanto, R. (2024). *A Lightweight Low-Light Image Enhancement Network via Channel Prior and Gamma Correction*. http://arxiv.org/abs/2402.18147

Yang, Z., Liao, Y., Chen, Z., Lin, Z., Huang, W., Liu, Y., Liu, Y., Fan, Y., Xu, J., Xu, L., & Mu, J. (2025). StomaYOLO: A Lightweight Maize Phenotypic Stomatal Cell Detector Based on Multi-Task Training. *Plants*, *14*(13). https://doi.org/10.3390/plants14132070

Yu, W., Yao, H., Li, D., Li, G., & Shi, H. (2021). Glagc: Adaptive dual-gamma function for image illumination perception and correction in the wavelet domain. *Sensors (Switzerland)*, *21*(3), 1–20. https://doi.org/10.3390/s21030845

Zhang, F., Ren, F., Li, J., & Zhang, X. (2022). Automatic stomata recognition and measurement based on improved YOLO deep learning model and entropy rate superpixel algorithm. *Ecological Informatics*, *68*. https://doi.org/10.1016/j.ecoinf.2021.101521

Zhang, F., Wang, B., Lu, F., & Zhang, X. (2023). Rotating Stomata Measurement Based on Anchor-Free Object Detection and Stomata Conductance Calculation. *Plant Phenomics*, *5*. https://doi.org/10.34133/plantphenomics.0106

Zou, Z., Shi, Z., Guo, Y., Ye, J., & Member, S. (n.d.). *Object Detection in 20 Years: A Survey*. https://doi.org/10.48550/arXiv.1905.05055

LAMPIRAN

Lampiran 1. *Code Gamma Correction and CLAHE*

```python
import os
import cv2
import numpy as np
import shutil

# Fungsi Preprocessing
def apply_gamma(image, gamma=1.5):
    inv_gamma = 1.0 / gamma
    table = np.array([(i / 255.0)**inv_gamma * 255 for i in range(256)]).astype("uint8")
    return cv2.LUT(image, table)

def apply_clahe(image):
    lab = cv2.cvtColor(image, cv2.COLOR_BGR2LAB)
    l, a, b = cv2.split(lab)
    clahe = cv2.createCLAHE(clipLimit=3.0, tileGridSize=(8,8))
    cl = clahe.apply(l)
    merged = cv2.merge((cl, a, b))
    return cv2.cvtColor(merged, cv2.COLOR_LAB2BGR)

# Folder asli dan tujuan
input_root = 'dataset'
output_root = 'dataset_processed'

splits = ['train', 'valid', 'test']
for split in splits:
    os.makedirs(f'{output_root}/{split}/images', exist_ok=True)
    os.makedirs(f'{output_root}/{split}/labels', exist_ok=True)

# Proses semua gambar
for split in splits:
    input_images = f'{input_root}/{split}/images'
    input_labels = f'{input_root}/{split}/labels'
    output_images = f'{output_root}/{split}/images'
    output_labels = f'{output_root}/{split}/labels'

    for filename in os.listdir(input_images):
        if not filename.lower().endswith(('.jpg', '.png', '.jpeg')):
            continue

        # Baca dan preprocessing
        img = cv2.imread(os.path.join(input_images, filename))
        if img is None:
            continue

        img = apply_gamma(img)
        img = apply_clahe(img)

        # Simpan hasil gambar
        cv2.imwrite(os.path.join(output_images, filename), img)

        # Salin label
        label_name = os.path.splitext(filename)[0] + '.txt'
        src_label = os.path.join(input_labels, label_name)
        dst_label = os.path.join(output_labels, label_name)
        if os.path.exists(src_label):
            shutil.copy(src_label, dst_label)
```

Lampiran 2. *Code Training Model*

```python
from ultralytics import YOLO
import pandas as pd
import os
import matplotlib.pyplot as plt

# === Load Model YOLO ===
model = YOLO('yolo11n.pt')  # Ganti nama model jika berbeda

# === Training ===
model.train(
    data='processed_data.yaml',
    epochs=100,
    imgsz=640,
    batch=32,
    name='stomata',
    project='en',
    val=True,
)
```

Lampiran 3. *Code Testing Model*

```python
import numpy as np
from ultralytics import YOLO
# === Load Model ===
model = YOLO(r'en/stomata/weights/best.pt')

# === Evaluasi pada data TEST ===
results = model.val(data=r'dataset/data.yaml', split='test', imgsz=640, batch=32)

# Ambil metrik dari hasil evaluasi
box = results.box
names = results.names
n_class = len(names)

# Confusion matrix
conf_matrix = results.confusion_matrix.matrix

# Precision, Recall, AP per kelas
precision_list = box.p      # Precision per kelas
recall_list = box.r         # Recall per kelas
ap50_list = box.ap50        # AP@50 per kelas
ap5095_list = box.ap        # AP@50-95 per kelas

# Hitung F1-score per kelas
f1_list = []
accuracy_list = []
for i in range(n_class):
    p = precision_list[i]
    r = recall_list[i]
    f1 = (2 * p * r / (p + r)) if (p + r) > 0 else 0.0
    f1_list.append(f1)

    # Hitung TP, FP, FN, TN
    TP = conf_matrix[i, i]
    FP = conf_matrix[:, i].sum() - TP
    FN = conf_matrix[i, :].sum() - TP
    TN = conf_matrix.sum() - (TP + FP + FN)

    # Accuracy per kelas
    acc = (TP + TN) / (TP + TN + FP + FN) if (TP + TN + FP + FN) > 0 else 0.0
    accuracy_list.append(acc)

    # === Tampilkan metrik per kelas ===
    print(f"\n===== Kelas: {names[i]} =====")
    print(f"TP: {int(TP)} | FP: {int(FP)} | FN: {int(FN)} | TN: {int(TN)}")
    print(f"Accuracy  : {acc:.4f}")
    print(f"Precision : {p:.4f}")
    print(f"Recall    : {r:.4f}")
    print(f"F1-score  : {f1:.4f}")
    print(f"AP@50     : {ap50_list[i]:.4f}")
    print(f"AP@50-95  : {ap5095_list[i]:.4f}")

# Konversi list ke numpy array
f1_list = np.array(f1_list)
accuracy_list = np.array(accuracy_list)

# === Rata-rata semua kelas ===
print("\n===== RATA-RATA (SEMUA KELAS) =====")
print(f"Average Accuracy  : {np.mean(accuracy_list):.4f}")
print(f"Average Precision : {np.mean(precision_list):.4f}")
print(f"Average Recall    : {np.mean(recall_list):.4f}")
print(f"Average F1-score  : {np.mean(f1_list):.4f}")
print(f"mAP@50 (avg)      : {np.mean(ap50_list):.4f}")
print(f"mAP@50-95 (avg)   : {np.mean(ap5095_list):.4f}")
```

Lampiran 4. *Result Training Model*

epoch	train/box_loss	train/cls_loss	train/dfl_loss	metrics/precision(B)	metrics/recall(B)	metrics/mAP50(B)	metrics/mAP50-95(B)	val/box_loss	val/cls_loss	val/dfl_loss
1	2,11475	2,6394	1,45218	0,67296	0,67636	0,73663	0,30391	1,88584	1,79883	1,34677
2	1,85662	1,26842	1,28822	0,70035	0,74029	0,76684	0,34899	1,74894	1,38314	1,34298
3	1,791	1,16644	1,2816	0,72612	0,83114	0,79235	0,35925	1,78077	1,2717	1,38123
4	1,77883	1,11094	1,28166	0,70839	0,78952	0,77281	0,33984	1,79767	1,24898	1,37412
5	1,76151	1,05337	1,27671	0,74687	0,82262	0,80426	0,35936	1,80888	1,15151	1,41504
6	1,73816	1,0003	1,27728	0,76234	0,86271	0,83227	0,35997	1,93178	1,10544	1,54669
7	1,72507	0,96834	1,27878	0,82478	0,86819	0,87625	0,42884	1,80198	0,96986	1,42865
8	1,71818	0,94109	1,27172	0,80906	0,79873	0,83819	0,3971	1,7805	1,03417	1,40245
9	1,70544	0,91263	1,26307	0,82183	0,87239	0,88993	0,4344	1,75083	0,91474	1,40966
10	1,69967	0,90198	1,26458	0,78965	0,8685	0,86705	0,41953	1,74989	1,02426	1,39897
11	1,69183	0,87814	1,26072	0,81815	0,85548	0,87245	0,4197	1,7902	0,95573	1,42864
12	1,69604	0,87944	1,25157	0,82068	0,88668	0,88752	0,43293	1,72865	0,89667	1,37961
13	1,68451	0,86232	1,25257	0,81009	0,89087	0,89072	0,44781	1,69998	0,92304	1,37568
14	1,68238	0,85884	1,25409	0,83195	0,89024	0,90745	0,46249	1,68367	0,87058	1,36776

15	1,67782	0,84249	1,24535	0,82198	0,87626	0,89449	0,44756	1,71609	0,87157	1,38135
16	1,66889	0,83102	1,2509	0,82992	0,8676	0,88742	0,42894	1,77296	0,8698	1,40748
17	1,66621	0,82274	1,24673	0,84114	0,86856	0,90289	0,45168	1,71689	0,85081	1,38439
18	1,6686	0,82	1,247	0,84725	0,88759	0,90932	0,45983	1,74894	0,81762	1,41486
19	1,66453	0,8117	1,24053	0,83551	0,87343	0,8962	0,44374	1,73607	0,86305	1,39836
20	1,65652	0,79922	1,23049	0,82872	0,87187	0,89396	0,45146	1,74663	0,84566	1,38247
21	1,65642	0,8025	1,24157	0,83314	0,87222	0,8983	0,44095	1,79439	0,86317	1,41415
22	1,65865	0,795	1,23582	0,83574	0,87649	0,90379	0,45538	1,7546	0,83843	1,40967
23	1,6505	0,78378	1,23615	0,84389	0,87057	0,89645	0,44878	1,74372	0,82231	1,39333
24	1,6437	0,77663	1,22964	0,84544	0,87414	0,90039	0,45161	1,75066	0,82116	1,39382
25	1,63897	0,77519	1,23589	0,83539	0,86334	0,8955	0,43406	1,81789	0,83255	1,4615
26	1,64469	0,77326	1,23363	0,82938	0,86314	0,88604	0,42897	1,80951	0,87649	1,43693
27	1,64482	0,77247	1,22926	0,84425	0,89074	0,91158	0,4574	1,74828	0,78929	1,39796
28	1,63909	0,76306	1,22322	0,84231	0,88068	0,90858	0,45181	1,74616	0,8006	1,39789
29	1,62856	0,7555	1,23332	0,82691	0,86402	0,88682	0,42793	1,81123	0,84279	1,44254
30	1,63237	0,75171	1,22214	0,84285	0,89257	0,91261	0,45826	1,76392	0,79595	1,42196

31	1,63409	0,75534	1,23067	0,83508	0,88672	0,90446	0,45618	1,76992	0,79676	1,42044
32	1,62539	0,74854	1,22173	0,85055	0,87269	0,91338	0,46237	1,74234	0,7902	1,40489
33	1,62858	0,74366	1,22554	0,84833	0,88618	0,91687	0,4774	1,70101	0,77043	1,3874
34	1,62335	0,74195	1,22206	0,84036	0,88112	0,90166	0,44524	1,80575	0,79123	1,46785
35	1,62002	0,73446	1,21917	0,84989	0,88974	0,91463	0,47418	1,74301	0,77012	1,41244
36	1,61442	0,73478	1,22304	0,83887	0,87686	0,90023	0,45041	1,8077	0,80995	1,45296
37	1,61356	0,73251	1,22391	0,85366	0,88688	0,91656	0,45721	1,77061	0,76488	1,42461
38	1,61511	0,73389	1,2175	0,8485	0,88191	0,91125	0,46789	1,7304	0,7638	1,39911
39	1,61592	0,72524	1,22164	0,84	0,88666	0,91252	0,46055	1,74327	0,77615	1,40446
40	1,60899	0,7268	1,22219	0,84231	0,88896	0,91522	0,46439	1,73519	0,7634	1,42068
41	1,61452	0,72267	1,22166	0,84762	0,87605	0,90401	0,4506	1,80327	0,78959	1,46425
42	1,60695	0,7166	1,21501	0,84258	0,89613	0,91875	0,47449	1,72764	0,75204	1,39861
43	1,59941	0,71435	1,22239	0,83985	0,88598	0,91716	0,47869	1,73309	0,74816	1,41242
44	1,60449	0,71509	1,21966	0,8523	0,87246	0,91383	0,46745	1,75538	0,75679	1,42774
45	1,59778	0,71109	1,21232	0,84884	0,87356	0,911	0,46918	1,73505	0,76213	1,41312
46	1,59717	0,706	1,22026	0,85184	0,88338	0,91858	0,4731	1,72551	0,74937	1,41895

47	1,59582	0,70731	1,21683	0,85001	0,87083	0,90246	0,44653	1,80341	0,76048	1,46056
48	1,59473	0,70622	1,2182	0,84675	0,88225	0,91366	0,45392	1,79703	0,77015	1,45803
49	1,59378	0,70429	1,21762	0,83751	0,88781	0,90809	0,46716	1,75101	0,76011	1,42613
50	1,58546	0,69888	1,21008	0,85292	0,88253	0,91514	0,46697	1,7546	0,74517	1,43275
51	1,59084	0,69924	1,21184	0,84187	0,89098	0,91469	0,4606	1,78293	0,75944	1,45642
52	1,58931	0,696	1,21466	0,84121	0,8915	0,91115	0,47111	1,75369	0,75449	1,43481
53	1,58075	0,69131	1,2066	0,84062	0,878	0,90474	0,44844	1,79512	0,75988	1,45582
54	1,57721	0,68786	1,20158	0,85382	0,8827	0,91639	0,47185	1,75591	0,73757	1,43786
55	1,58227	0,69238	1,207	0,84984	0,87425	0,91107	0,45821	1,77554	0,74435	1,44534
56	1,57446	0,68617	1,21028	0,84039	0,89105	0,91265	0,46638	1,76359	0,73863	1,44435
57	1,57917	0,68467	1,20469	0,83756	0,89238	0,91493	0,46447	1,79101	0,73378	1,45416
58	1,57376	0,68314	1,20271	0,85218	0,88468	0,91923	0,46792	1,75363	0,74218	1,42954
59	1,5678	0,67811	1,20218	0,85478	0,87992	0,91279	0,46804	1,76239	0,73871	1,43907
60	1,57035	0,67664	1,20157	0,85255	0,8755	0,91256	0,46206	1,80113	0,74901	1,46851
61	1,56159	0,67045	1,20287	0,8415	0,89138	0,91472	0,46123	1,77859	0,74334	1,45837
62	1,56118	0,67045	1,20186	0,8393	0,88379	0,90617	0,45801	1,8023	0,75162	1,47541

63	1,56653	0,67355	1,20205	0,84887	0,8887	0,91453	0,46108	1,78252	0,72765	1,46345
64	1,5605	0,66764	1,1956	0,85158	0,87364	0,91299	0,45725	1,80029	0,74063	1,46533
65	1,5559	0,66991	1,20192	0,84988	0,88557	0,9115	0,45511	1,80287	0,72756	1,47658
66	1,55223	0,66281	1,1988	0,85564	0,87173	0,90984	0,45662	1,7957	0,73266	1,47253
67	1,55121	0,66357	1,20063	0,85006	0,88189	0,911	0,46328	1,78882	0,73782	1,47449
68	1,55118	0,65986	1,19638	0,85255	0,8862	0,92091	0,47602	1,74882	0,73081	1,43621
69	1,54695	0,65981	1,19753	0,84678	0,88244	0,91154	0,45698	1,7965	0,74137	1,47627
70	1,53932	0,65389	1,19719	0,85616	0,87622	0,91419	0,46447	1,78197	0,73018	1,46583
71	1,54151	0,65798	1,20004	0,8431	0,88586	0,91263	0,46209	1,78972	0,73363	1,46483
72	1,53617	0,6489	1,19501	0,84354	0,88802	0,91164	0,4646	1,76451	0,72842	1,4495
73	1,53732	0,65106	1,18735	0,85316	0,87945	0,91373	0,45475	1,81087	0,73334	1,47825
74	1,53515	0,6501	1,19128	0,84311	0,88715	0,91143	0,46283	1,78705	0,73742	1,46193
75	1,53216	0,64847	1,19078	0,85982	0,87247	0,90623	0,45019	1,81444	0,72903	1,48442
76	1,52833	0,64297	1,19056	0,84044	0,88969	0,90855	0,45761	1,79625	0,73144	1,47379
77	1,52673	0,64406	1,19573	0,85669	0,87173	0,90703	0,45497	1,80762	0,72668	1,48524
78	1,5205	0,6381	1,18928	0,83811	0,89079	0,90936	0,459	1,79656	0,72966	1,4716
79	1,52259	0,63865	1,19221	0,84376	0,88803	0,91273	0,46175	1,78645	0,72407	1,46664

80	1,5156	0,63633	1,18425	0,84907	0,88336	0,91075	0,45422	1,82168	0,7244	1,49034
81	1,51371	0,63509	1,18489	0,84384	0,88616	0,90881	0,45484	1,79713	0,7237	1,4772
82	1,51709	0,63333	1,18408	0,83974	0,89227	0,91219	0,46269	1,77887	0,72726	1,4682
83	1,5157	0,6345	1,17566	0,84205	0,89299	0,91308	0,46174	1,77687	0,72073	1,46945
84	1,50987	0,63142	1,18191	0,84604	0,88744	0,91171	0,4624	1,7832	0,72476	1,46912
85	1,5141	0,63381	1,18972	0,84802	0,88572	0,91379	0,4603	1,79555	0,73037	1,48055
86	1,50525	0,62998	1,18093	0,84142	0,88476	0,9091	0,45119	1,82391	0,73578	1,50339
87	1,50114	0,62819	1,17909	0,84289	0,88342	0,90919	0,4592	1,79472	0,72983	1,48012
88	1,49776	0,62575	1,17718	0,84604	0,88375	0,90854	0,45432	1,8144	0,72966	1,50038
89	1,49835	0,62404	1,17623	0,84784	0,88514	0,90986	0,45843	1,80241	0,73051	1,48868
90	1,49835	0,62494	1,18157	0,84831	0,88948	0,91165	0,46103	1,80075	0,71662	1,48673
91	1,50214	0,59597	1,2241	0,8427	0,88815	0,91058	0,45504	1,79068	0,71893	1,47999
92	1,47823	0,58056	1,21982	0,84853	0,88243	0,91033	0,45525	1,79193	0,72615	1,48797
93	1,47297	0,57718	1,21795	0,84231	0,88667	0,90914	0,46075	1,77833	0,72436	1,47345
94	1,46542	0,57506	1,20968	0,83446	0,89774	0,90942	0,4599	1,78447	0,72335	1,48378
95	1,46369	0,57323	1,21064	0,84492	0,88376	0,90766	0,4574	1,79414	0,7239	1,49089
96	1,45724	0,56937	1,20875	0,84573	0,88547	0,90859	0,45927	1,79247	0,7236	1,48711

97	1,45389	0,56891	1,20555	0,84722	0,8828	0,90859	0,45986	1,79615	0,72471	1,48893
98	1,44865	0,56664	1,2028	0,84596	0,8844	0,90935	0,45962	1,79469	0,724	1,49219
99	1,44966	0,56672	1,20472	0,84397	0,88377	0,90796	0,45928	1,79531	0,72417	1,49271
100	1,44413	0,56215	1,20366	0,84681	0,88306	0,91015	0,46254	1,78867	0,7228	1,48757